

# Umelá inteligencia 2026

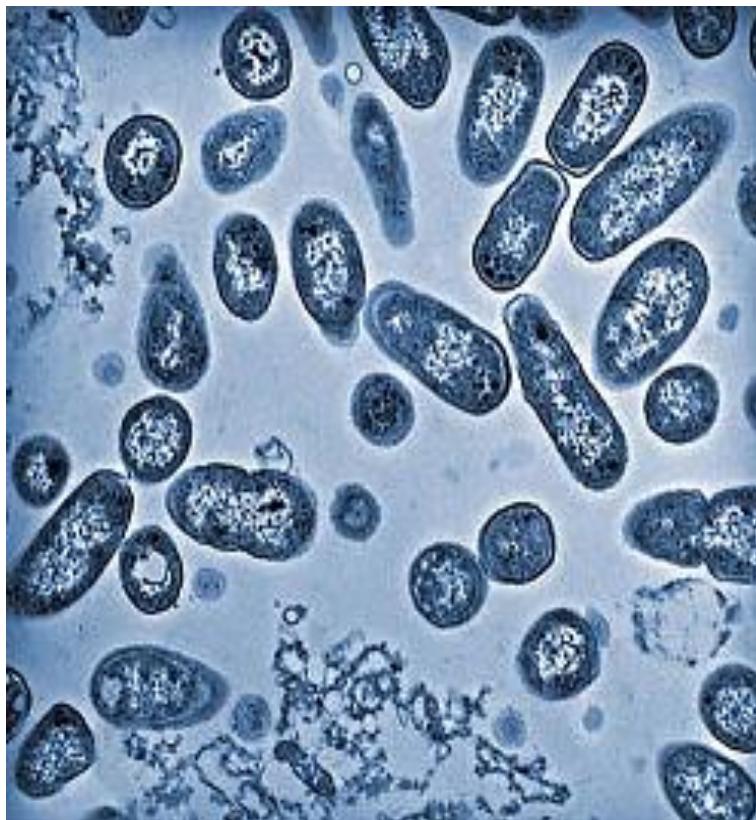
Ivan Sekaj

Ústav robotiky a kybernetiky  
FEI STU Bratislava  
[ivan.sekaj@stuba.sk](mailto:ivan.sekaj@stuba.sk)



# **Úvod a motivácia**

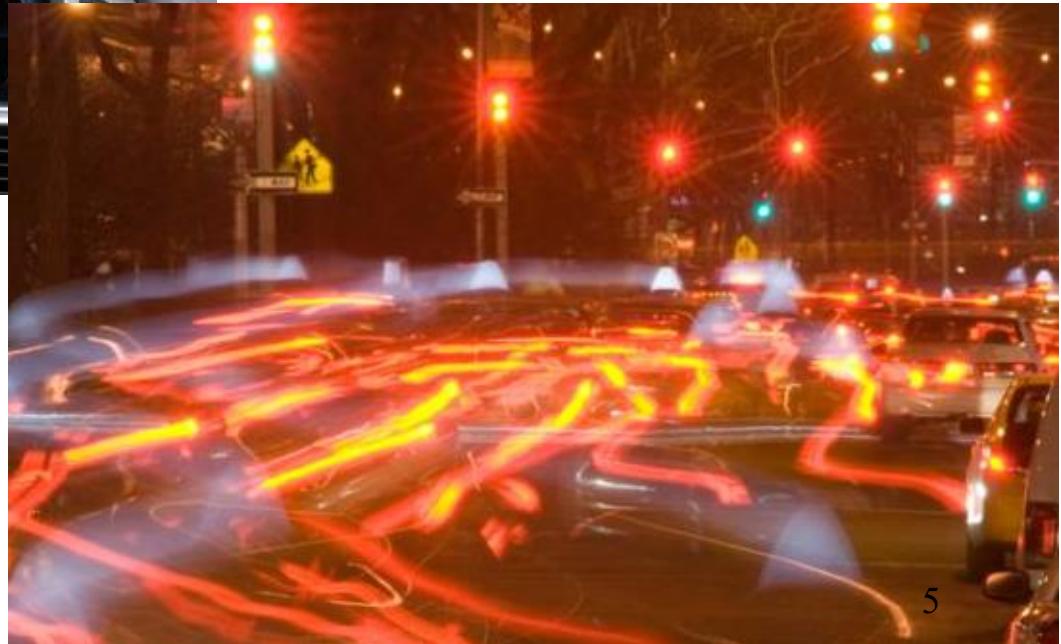
# Motivácia



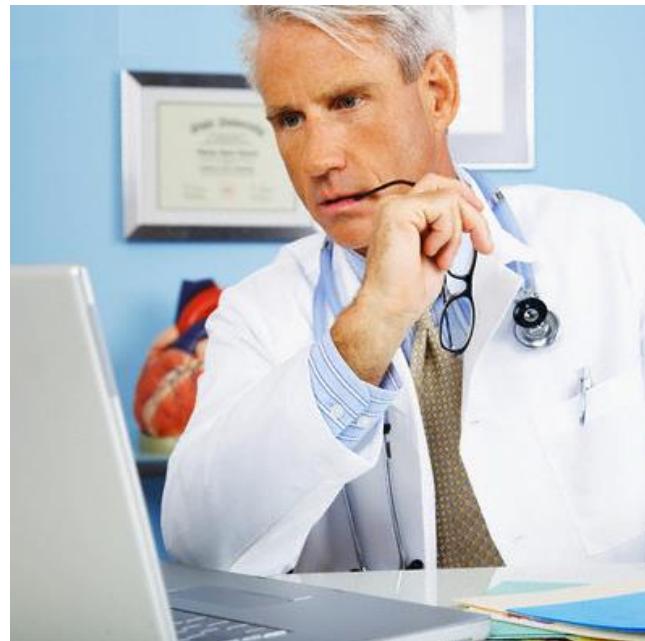
# Motivácia



# Motivácia



# Motivácia

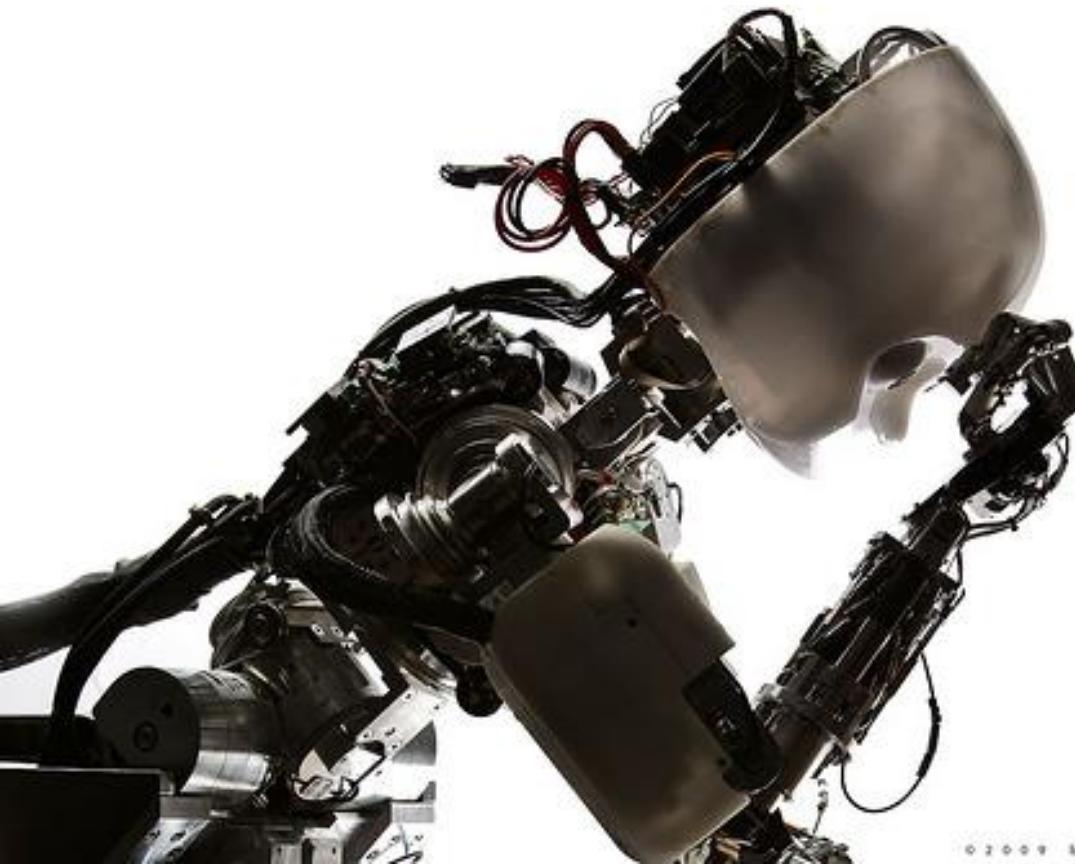


# Prirodzená inteligencia

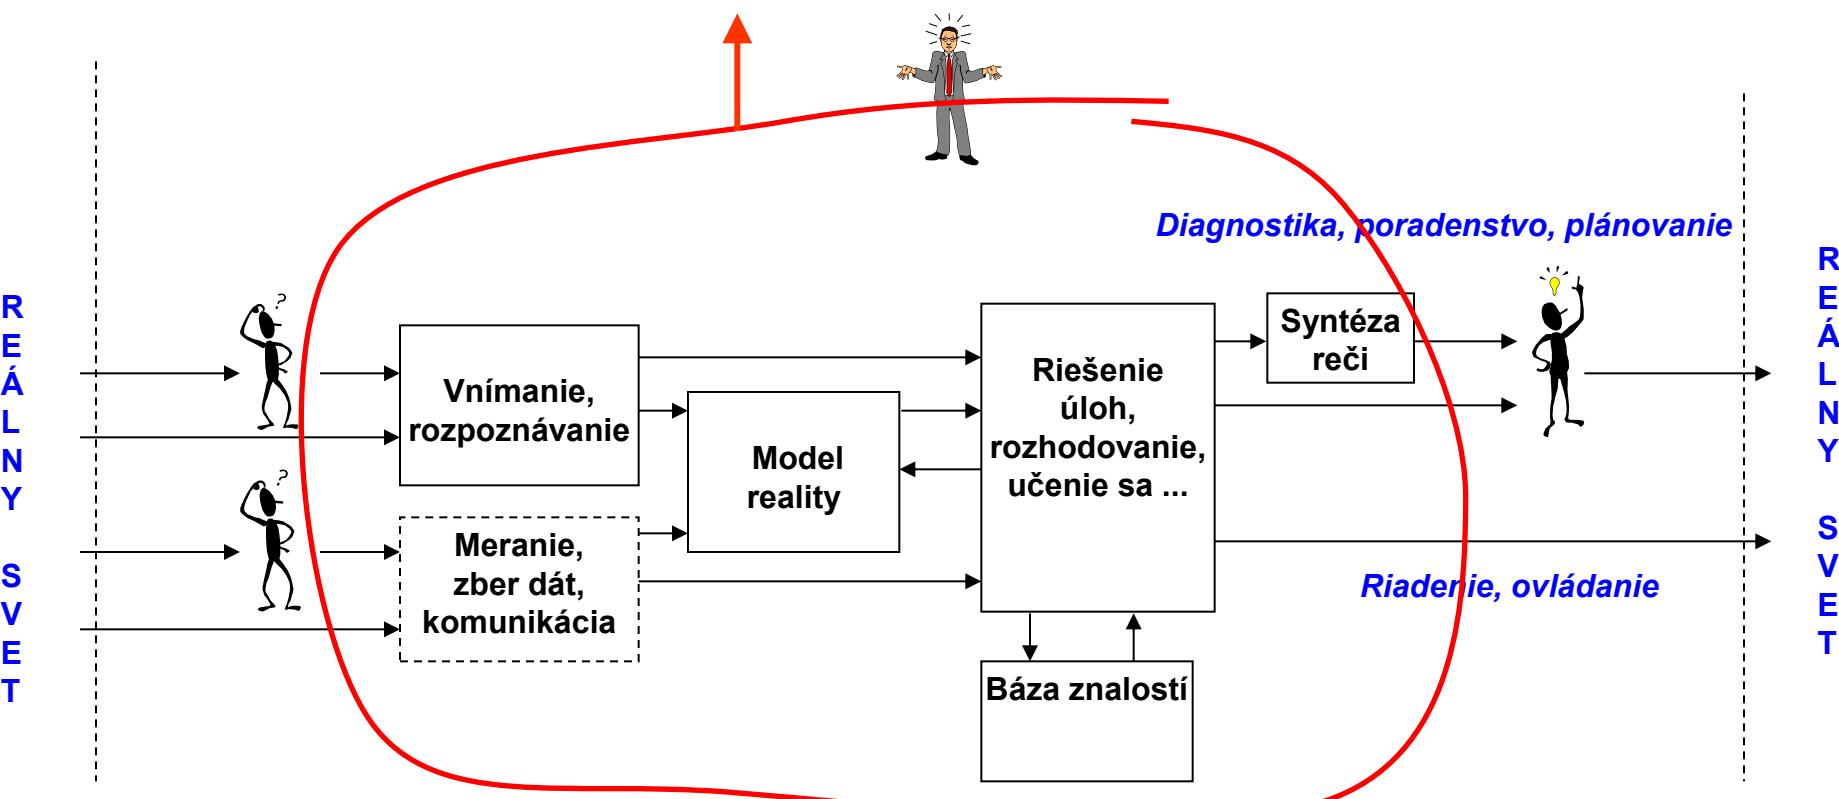


**Prirodzená inteligencia je vlastnosťou živých organizmov vyjadrujúca mieru ich schopnosti efektívne reagovať na prejavy prostredia a aktívne ich využívať vo svoj prospech.**

- Môžu stroje myslieť ?  
Môžu počítače napodobniť alebo nahradit' prirodzenú inteligenciu ?
- Snaha napodobniť prirodzenú inteligenciu → umelá inteligencia



# Umelá inteligencia



# **“Výpočtová inteligencia” ( Computational intelligence, Soft computing )**

- evolučné výpočtové metódy
- umelé neurónové siete
- fuzzy logika

+ Generatívna UI

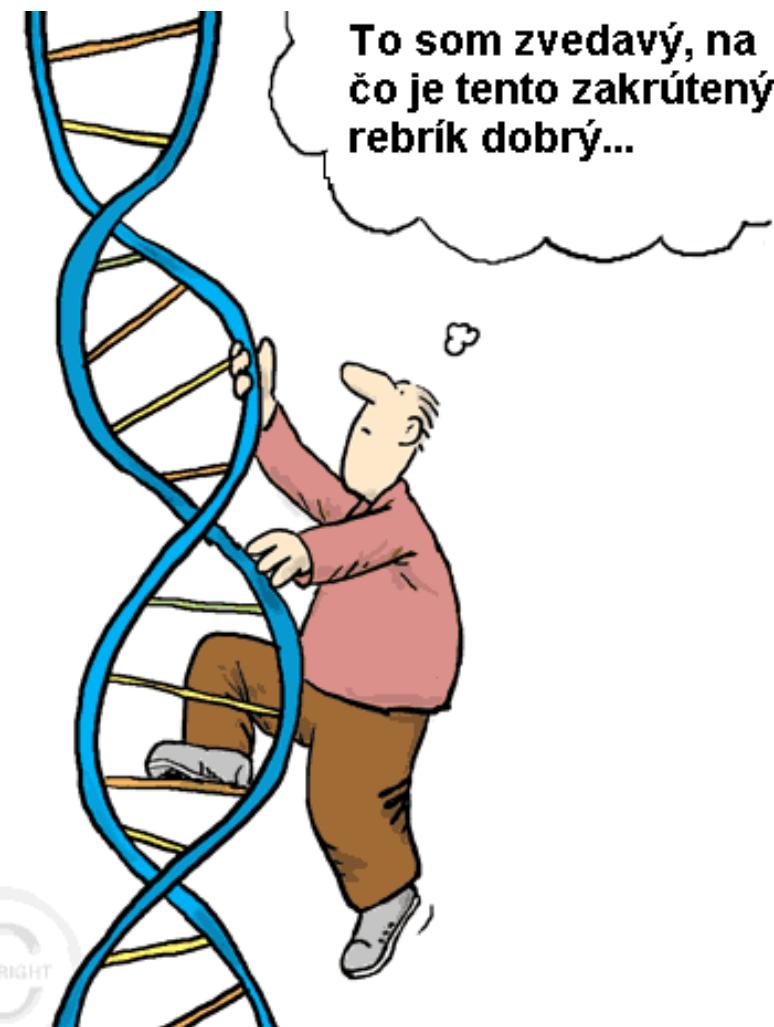
+ iné prístupy

Náš  
predmet  
UI

Umelá  
inteligencia<sup>10</sup>

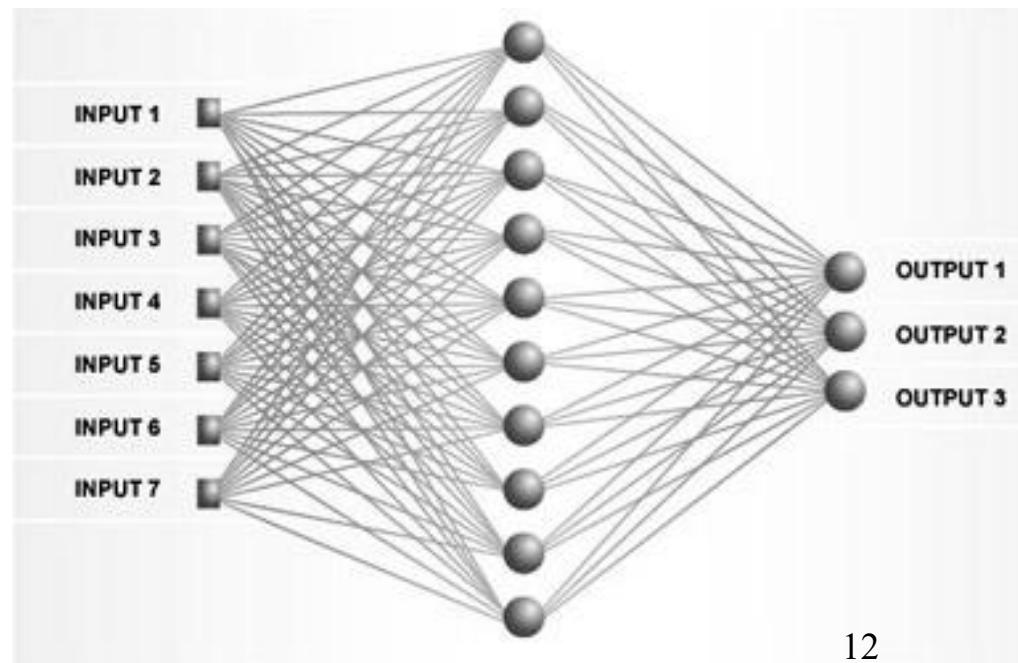
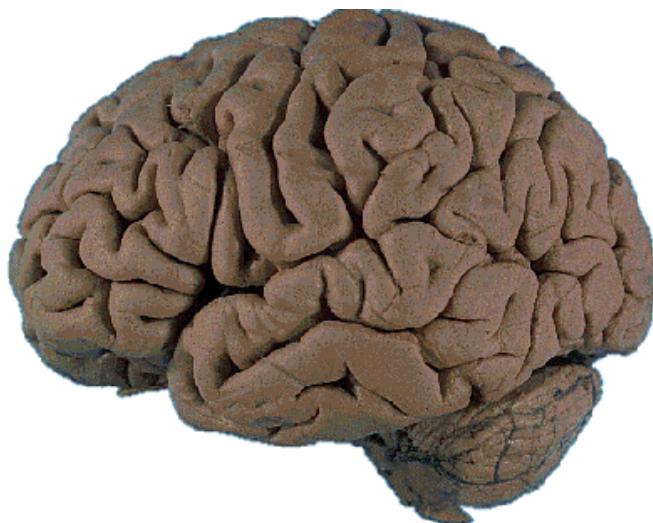
# Evolučné / Genetické algoritmy

optimalizačný prístup napodobujúci evolúciu v živej prírode, vhodný na riešenie mnohých typov úloh



# Umelé neurónové siete

prístup vhodný na modelovanie, predikciu,  
rozpoznávanie, klasifikáciu objektov a javov,  
napodobuje vnútornú štruktúru mozgu



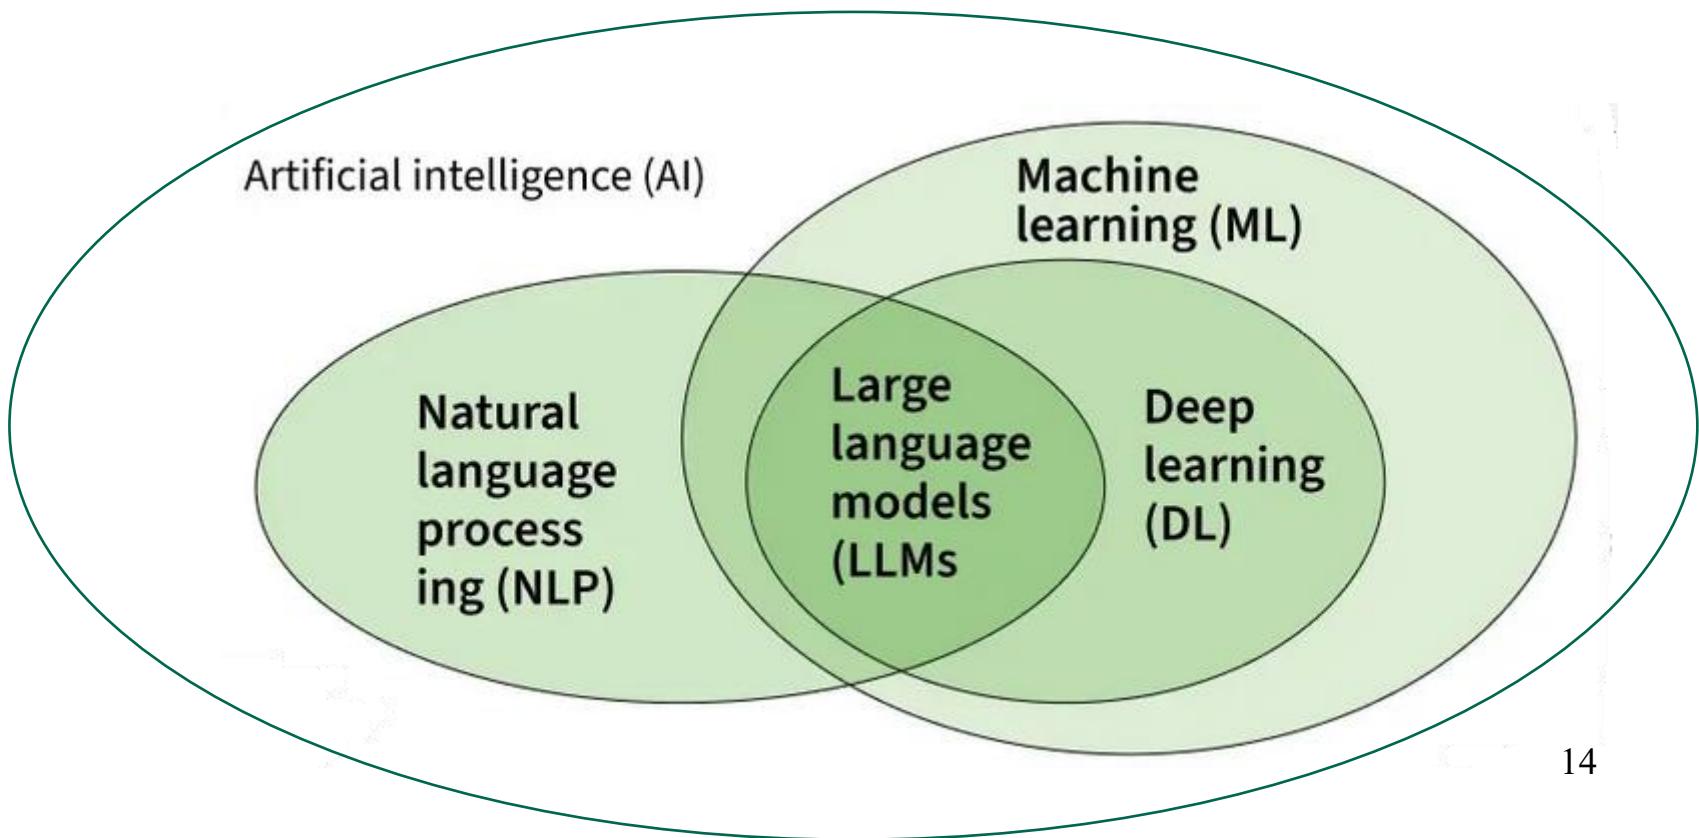
# Fuzzy logika

znalostný systém napodobujúci ľudské uvažovanie  
a rozhodovanie pravidlového typu,  
ktoré sú formulovateľné ľudskou rečou



# Generatívna UI

veľké jazykové modely, transformery, agenty  
stručný prehľad problematiky



# **Ciel' predmetu UI**

- Oboznámiť sa so základmi vybraných prístupov UI
- Tvorba jednoduchých aplikácií UI pri riešení praktických problémov

# **Obsah predmetu UI**

- základy evolučných výpočtových metód, základy genetických algoritmov (GA)
- aplikácie GA pri riešení problémov
- základy umelých neurónových sietí (UNS)
- základy strojového učenia
- použitie UNS
- UNS v praktických aplikáciách
- fuzzy logika (FL)
- Generatívna UI, LLM
- súčasný stav a perspektívy UI
- používanie nástrojov UI v školstve a vede

# Prehľad cvičení

1. Úvod, úloha 1: Horolezecký algoritmus, 1 bod
  2. Úloha 2: Genetický algoritmus, testovacia funkcia, 4 b
  3. Úloha 3: Genetický algoritmus, dopravný problém, 4 b
  4. Úloha 4: Genetický algoritmus, finančná úloha, 5 b
  5. Úloha 5: Demo ukážky - neurónové siete, klasifikácia, approximácia, 0 b
  6. Úloha 6: MLP, klasifikácia medicínskych dát, 4 b
  7. Úloha 7: Rozpoznávanie číslic, MLP a CNN, 7 b
  8. Test, 15 b
  9. Úloha 8: CNN, transfer learning, tuning, datasety, 5 b
  10. Úloha 9: Fuzzy logika, riadenie križovatky, 5 b
  - 11.-12. Odovzdávanie zadania
- Projekty sa odovzdávajú osobne svojmu učiteľovi na cvičení, v priebehu nasledovného cvičenia. Omeškanie týždeň po termíne: 50% bodov.  
Neskôr: 0%.
  - Bonusové úlohy (konzultovať so Sekajom), max + 10 bodov.

# Hodnotenie

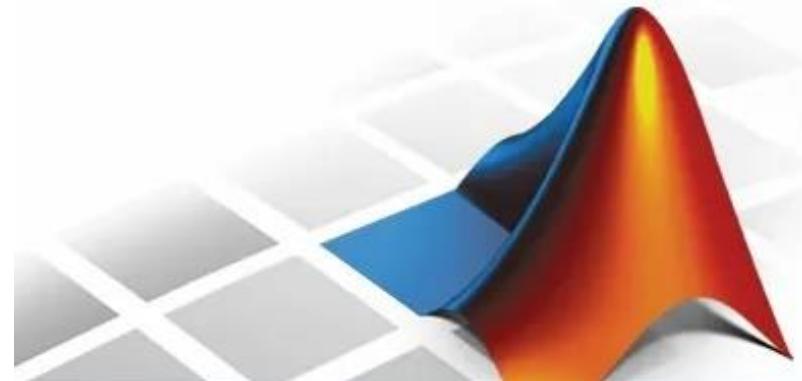
Cvičenia .....	$1+4+4+5+0+4+7+5+5=35$ b
Test .....	15 b
Bonusová úloha.....	10 b
Skúška .....	50 b
 Spolu :	 110 b

Podmienka pre účasť na skúške: 20 bodov z úloh 1-9

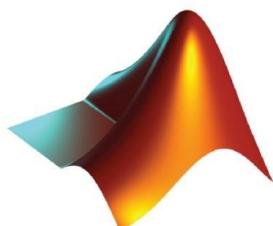
Podmienka pre získanie skúšky: 15 bodov z písomnej skúšky

# Prostredie používané na cvičeniach

**krátky\_kurz\_Matlab.pdf**



**Web:**



**MATLAB  
for  
Beginners**

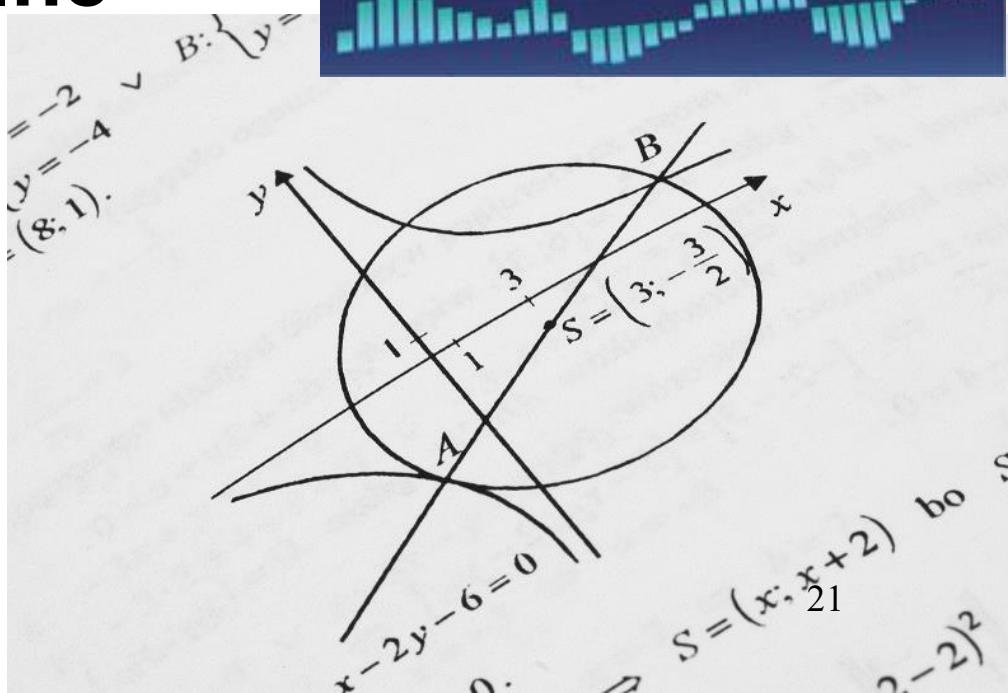


# **Optimalizácia a aplikáčné domény optimalizačných metód**

- Analytické (matematické) prístupy
- Numerické prístupy
- Bio-inšpirované prístupy

# Matematika (aj UI)

- extremalizácia funkcií
- kombinatorika
- grafové úlohy
- regresná analýza
- teória hier, optimálne strategie
- „hľadanie riešení“
- a veľ'a iného ...

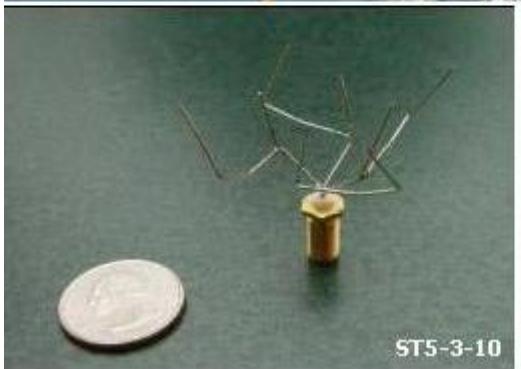
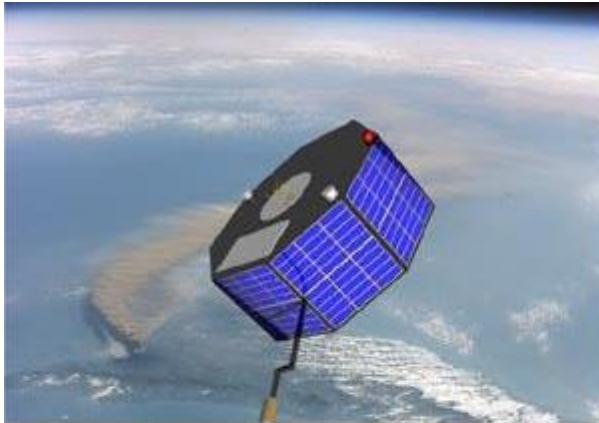


# **Ekonómia a finančníctvo**

- optimalizácia výrobného sortimentu
- plánovanie výroby
- dopravné úlohy
- alokácia investícií
- optimalizácia finančných operácií
- a veľa iného ...



# Príklay koštrukčných úloh



# Informatika a komunikácia

- optim. spojenia v poč./telekom. sieti
- de / šifrovanie
- automatizované programovanie
- strojové učenie
- porozumenie textu, reči, vyhodnotenie, automatizované spracovanie, ...
- ?



# Automatizácia, robotika



# **Bio-inšpirované optimalizačné výpočtové prístupy**

**Evolučné algoritmy**

**Genetický algoritmus a  
genetické programovanie**

# 1 Genetický algoritmus



# **1.1 Optimalizácia, hl'adanie riešení**

# Optimalizačná úloha

Lokálny extrém - lokálne maximum:

$$x_{\text{opt}} \in P$$

pre všetky  $x \in P$ :  $f(x_{\text{opt}}) > f(x)$

$P$  je podpriestor  $D$  ( $P$  - okolie lokálneho extrému)

$D$  je podpriestor  $R^N$ , ( $D$  – celý prehľadávaný priestor, definičný obor)

$N$  – počet optimalizovaných premenných  
(dimenzia problému)

Globálny extrém - globálne maximum:

$$x_{\text{opt}} \in D$$

Globálne maximum

Lokálne maximum

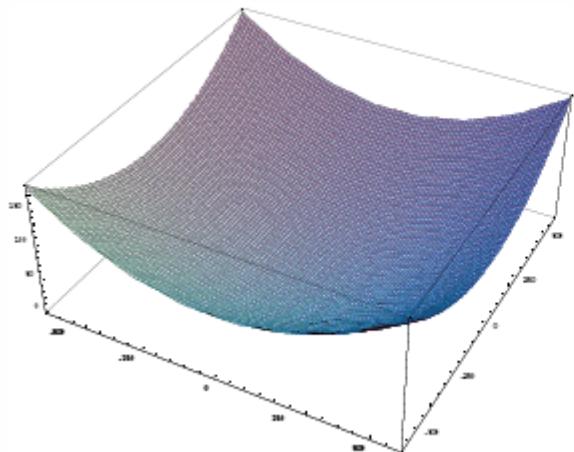
Globálne minimum

Lokálne minimum

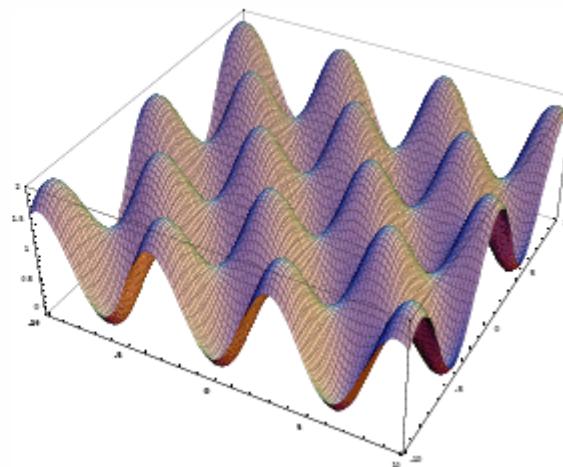


$$X^* = [x_1^*; x_2^*] = ? ; F(X^*) \rightarrow \max$$

**unimodálna funkcia  
má 1 extrém – minimum  
(maximum)**



**multimodálna funkcia  
má viac lokálnych extrémov,  
jeden globálny extrém  
(niekedy viac rovnakých)**



# Optimalizovaný problém (matematický, technický, ekonomický, ...)

Optimalizovaný objekt (potenciálne riešenie):

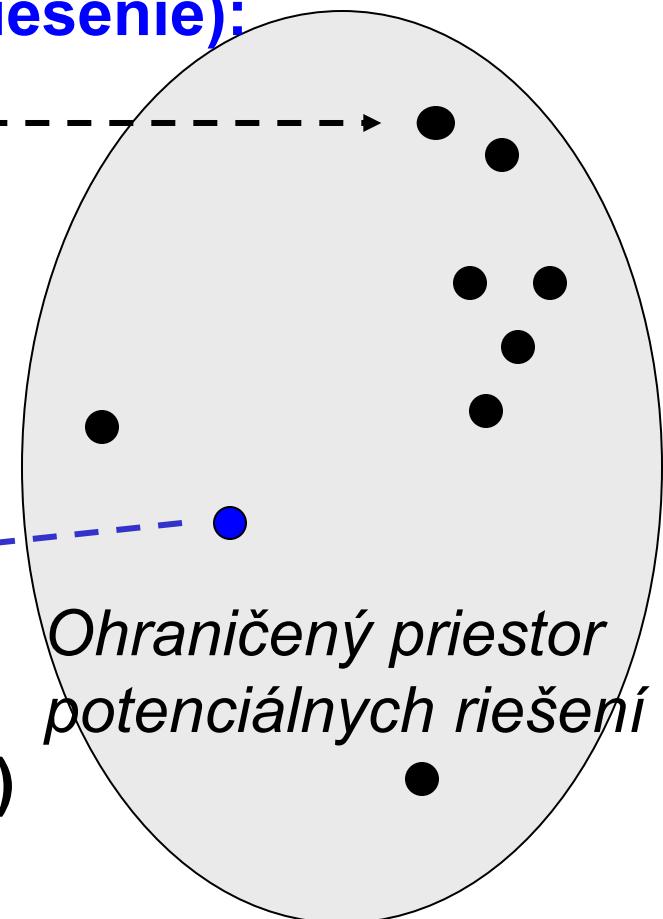
$$X_i = \{x_{i,1} \ x_{i,2} \ x_{i,3} \ \dots \ x_{i,n}\}$$

$x_{i,j}$  – parametre pevnej štruktúry objektu alebo

$x_{i,j}$  – kód štrukturálnych väzieb objektu

$x_{i,j}$  – kombinácia oboch

$$X_{\text{opt}} = ?$$



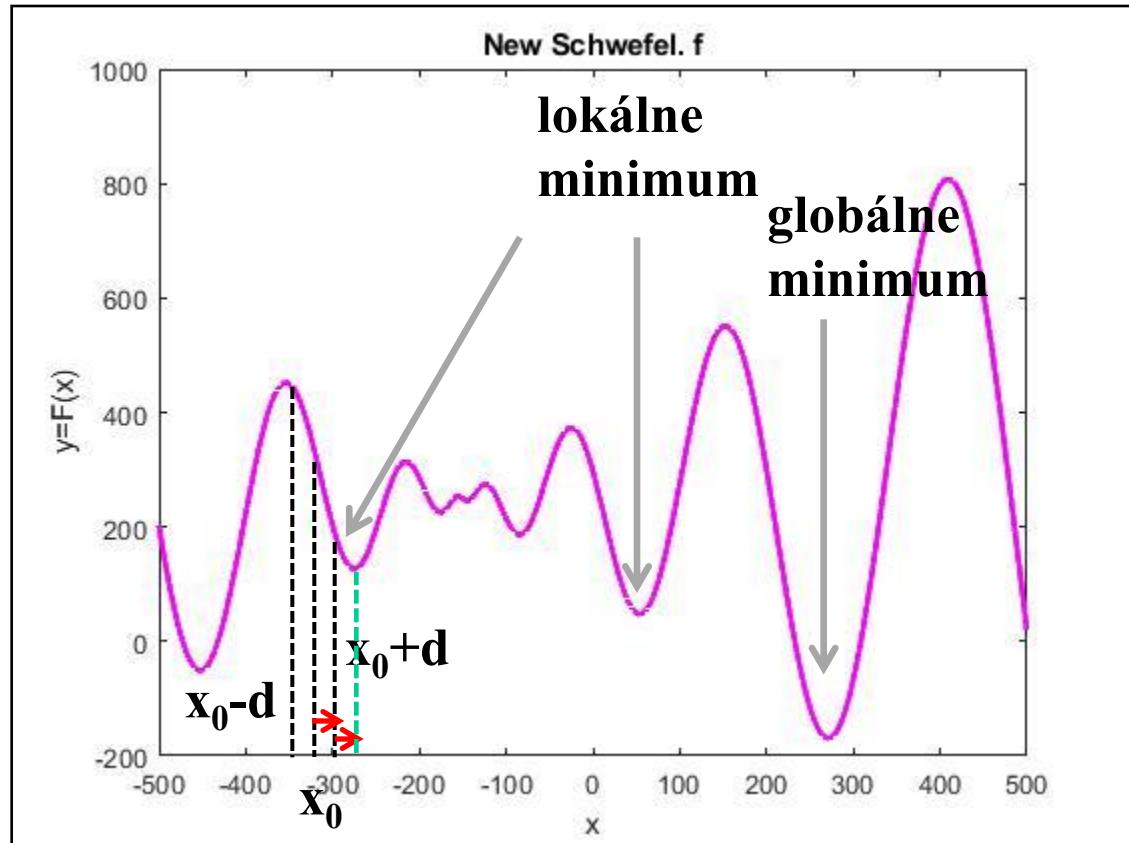
účelová funkcia :  $F(X_{\text{opt}}) \rightarrow \min \ (\max)$

$F$  – matematicky formulovaná funkcia

$F$  – procedúra na vyhodnotenie úspešnosti daného riešenia  
(výpočet, program, počítačová simulácia, ...)

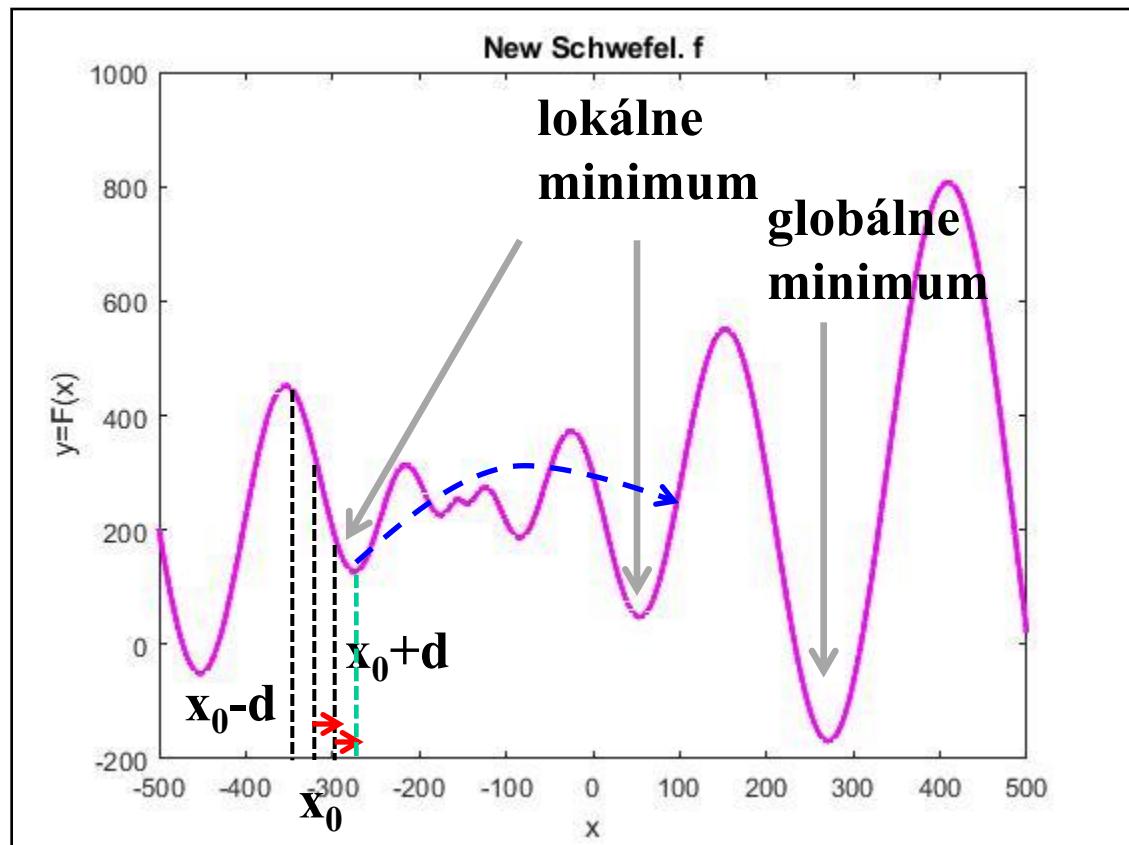
# Horolezecký algoritmus (Hillclimbing alg.)

1. začni v náhodnom bode  $x_0$  def. oboru na osi x, vyhodnot' funkciu  $y=F(x_0)$
2. prehľadaj susedov naľavo a napravo vo vzdialosti 1 kroku  $d$ , vyhodnot' funkciu v bodoch  $y=F(x_0-d)$ ,  $y=F(x_0+d)$
3. ak je hodnota funkcie v niektorom z týchto bodov menšia, premiestni aktuálne riešenie do tejto novej pozície
4. ak už nie je nájdená menšia hodnota  $y$  alebo bol uskutočnený už požadovaný počet krovov, skonči, inak pokračuj v bode 2

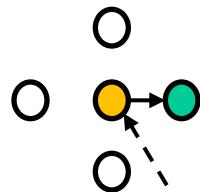


# Stochastický horolezecký algoritmus

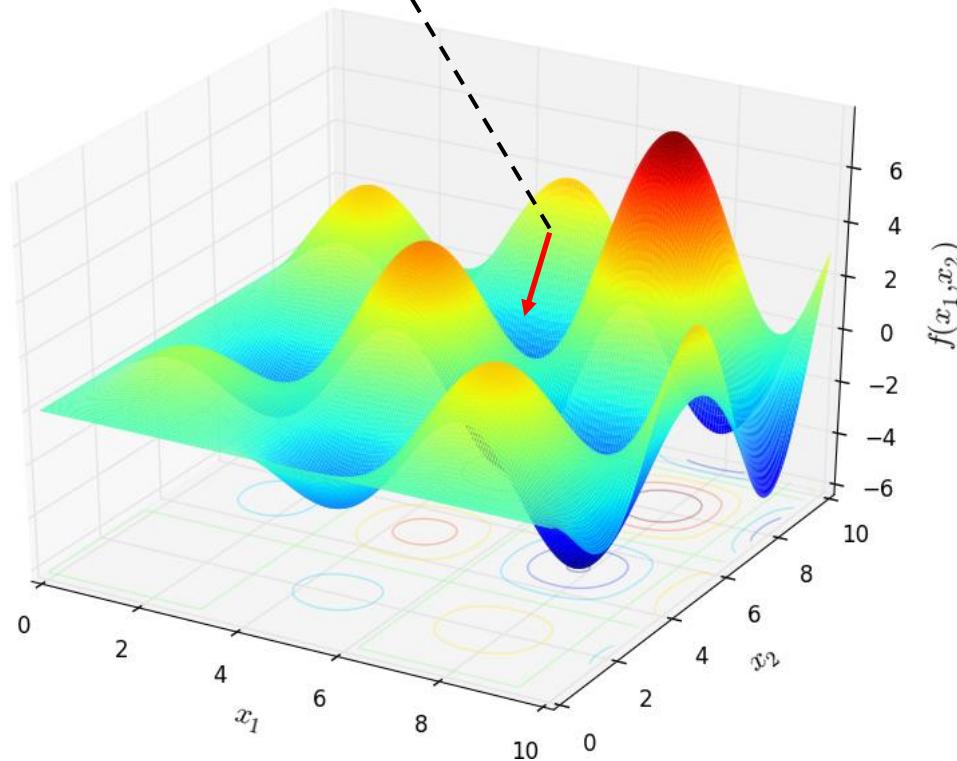
1. začni v náhodnom bode  $x_0$  def. oboru na osi x, vyhodnot' funkciu  $y=F(x_0)$
2. prehľadaj susedov naľavo a napravo vo vzdialosti 1 kroku  $d$ , vyhodnot' funkciu v bodoch  $y=F(x_0-d)$ ,  $y=F(x_0+d)$
3. ak je hodnota funkcie v niektorom z týchto bodov menšia, premiestni aktuálne riešenie do tejto novej pozície
4. ak už nie je nájdená menšia hodnota  $y$ , preskoč na náhodný bod v priestore, pokračuj v bode 2
5. ak už bol uskutočnený požadovaný počet krovov, skonči



## Horolezecký algoritmus - 2D úloha



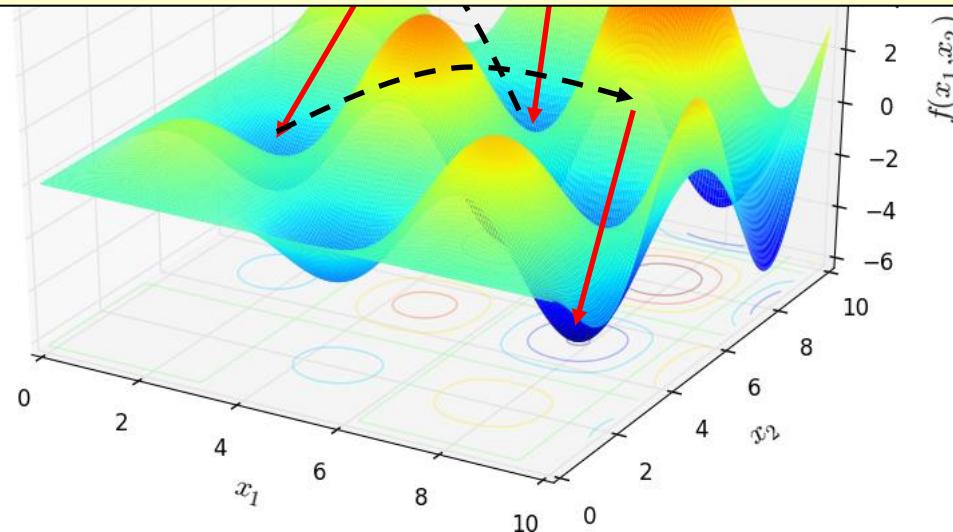
2D: prehľadanie  $2^2$  susedov  
ND: prehľadanie  $2^N$  susedov



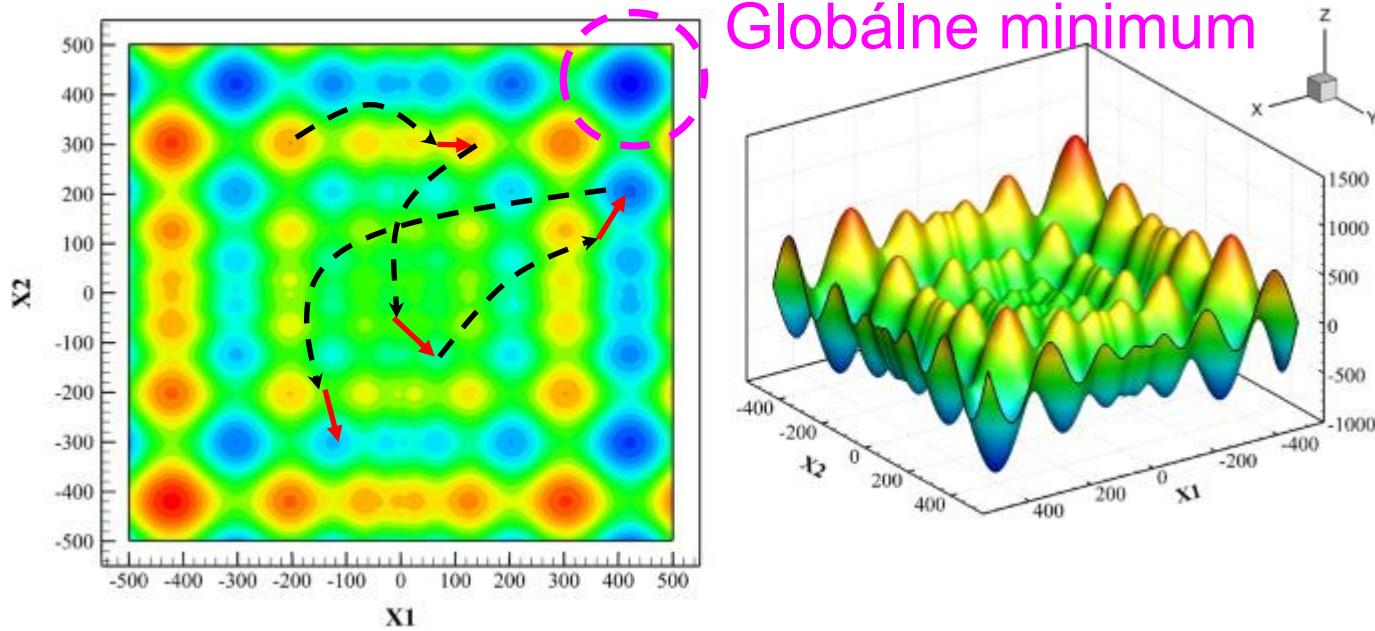
Horolezecký algoritmus uviazne v najbližšom lokálnom extréme.

# Stochastický Horolezecký algoritmus - 2D úloha

1. začni v náhodnom bode  $[x_0, y_0]$  def. oboru na osiach x, y. Vyhodnot' funkciu  $z=F(x_0, y_0)$ .
2. prehľadaj susedov naľavo a napravo, hore a dolu vo vzdialnosti 1 kroku o veľkosti  $d$ .
3. ak je hodnota funkcie v niektorom z týchto bodov menšia, premiestni aktuálne riešenie do tejto novej pozície. Pokračuj v bode 2.
4. ak už nie je nájdená menšia hodnota, skoč na iný náhodný bod priestoru, pokračuj v bode 2.



## 2D úloha – Schwefelova funkcia



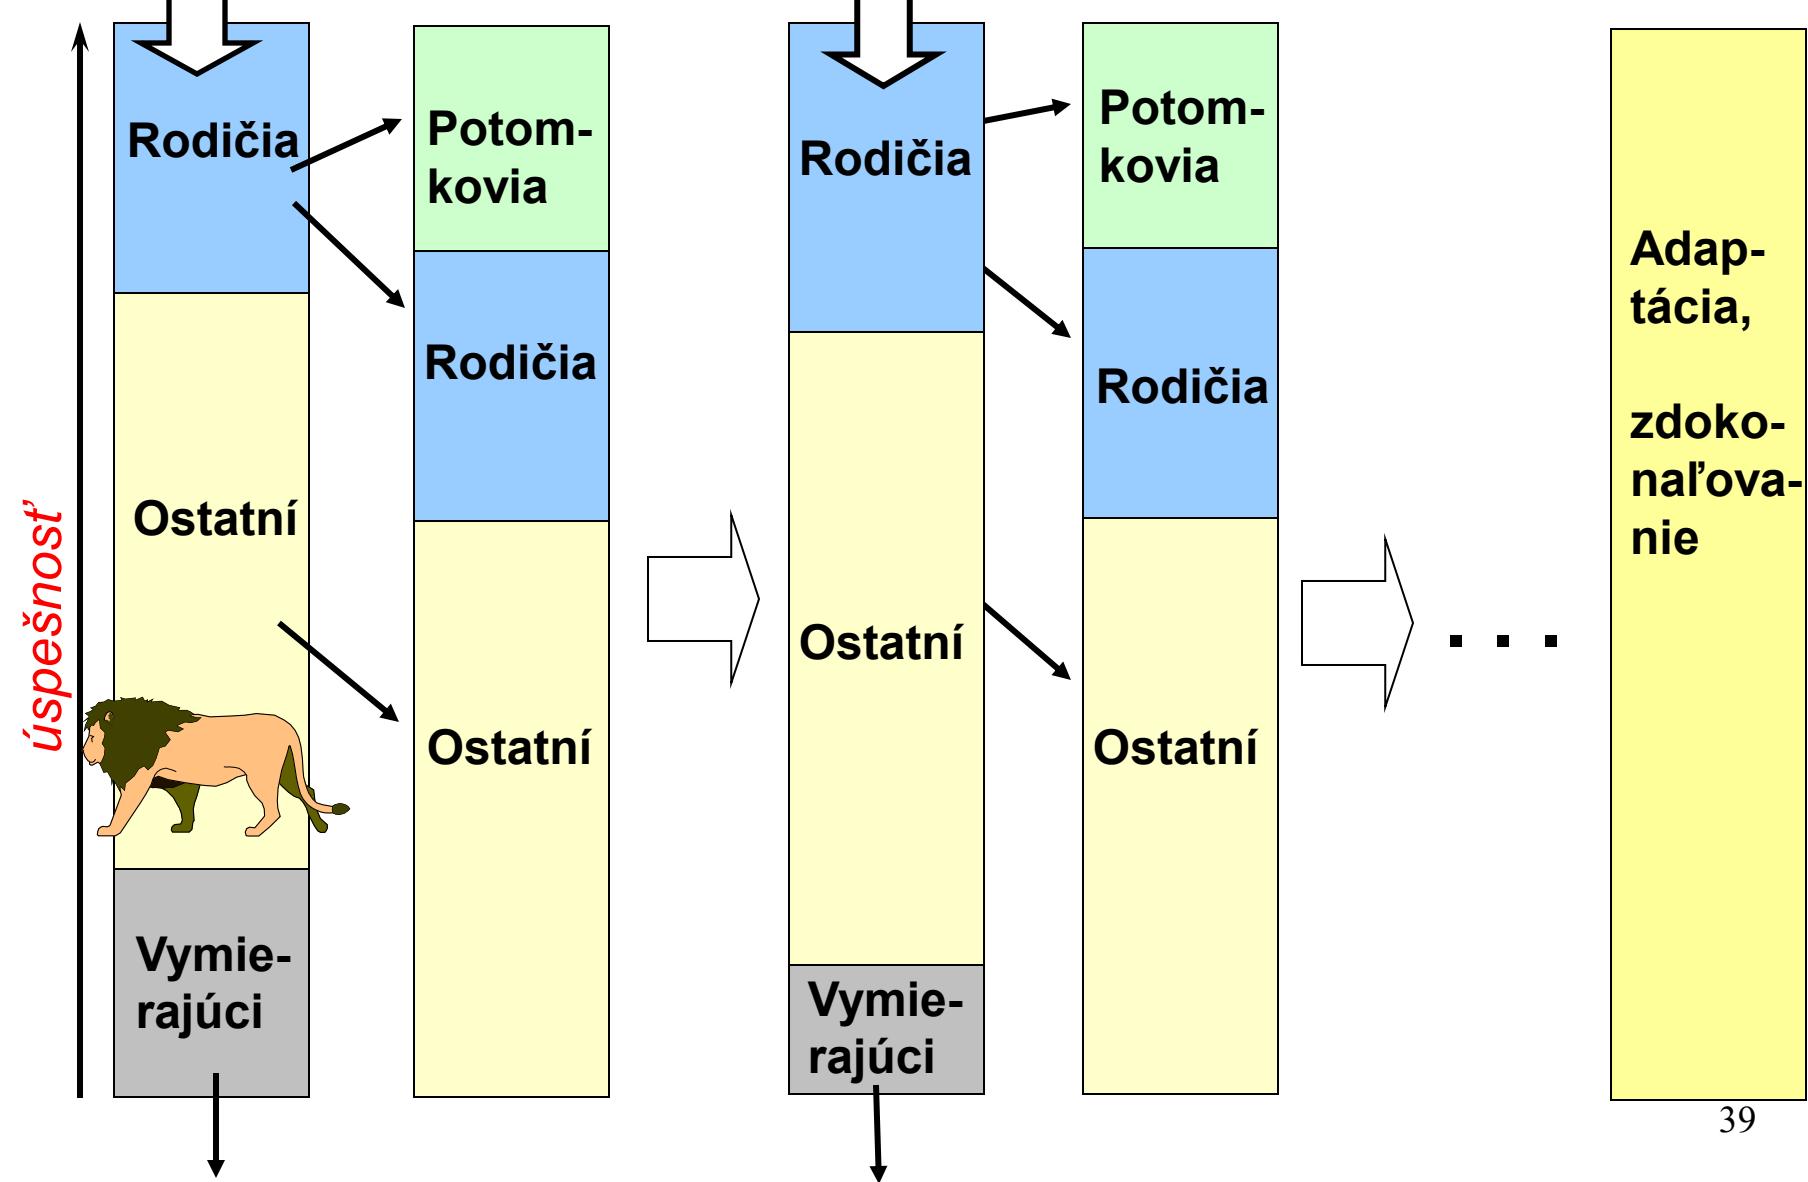
**10D úloha / 100D úloha  
Použitie Horolezeckého algoritmu ?**

Pre viac než 3D úlohu začína byť použitie Horolezeckého algoritmu výpočtovo neúnosné.

# **1.2 Genetický algoritmus, úvod**

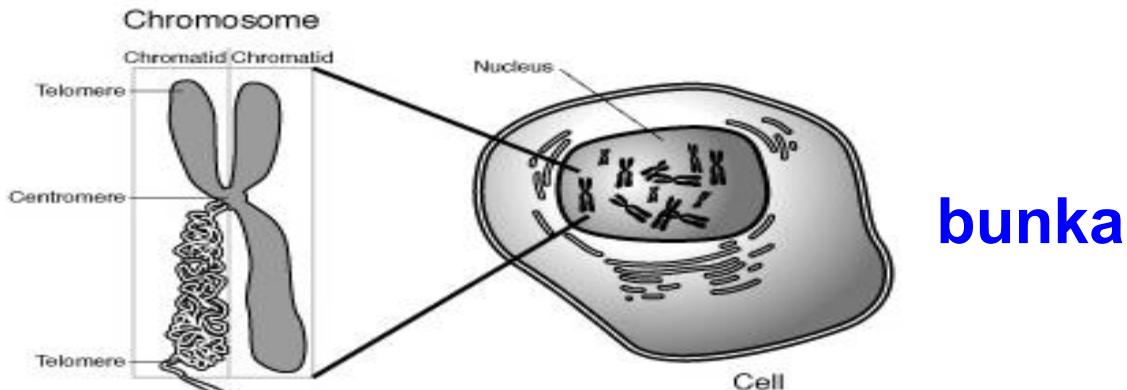
# **Zjednodušený model evolúcie v prírode**

## Vplyvy prostredia, boj o prežitie, konkurenčný boj o potravu, zápas o partnerov

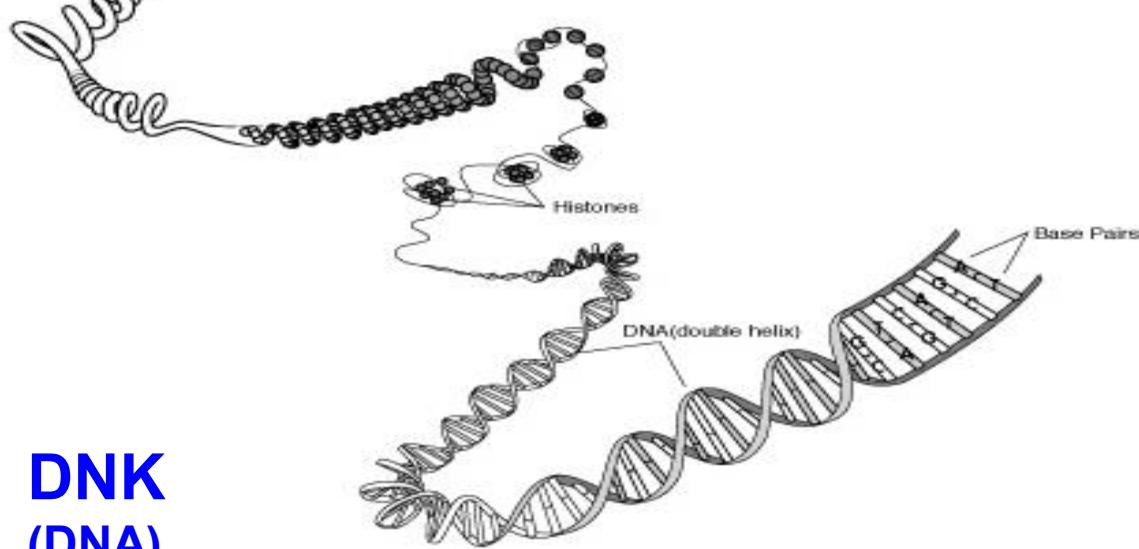


# Genóm – kompletná genetická informácia daného jedinca

chromozómy



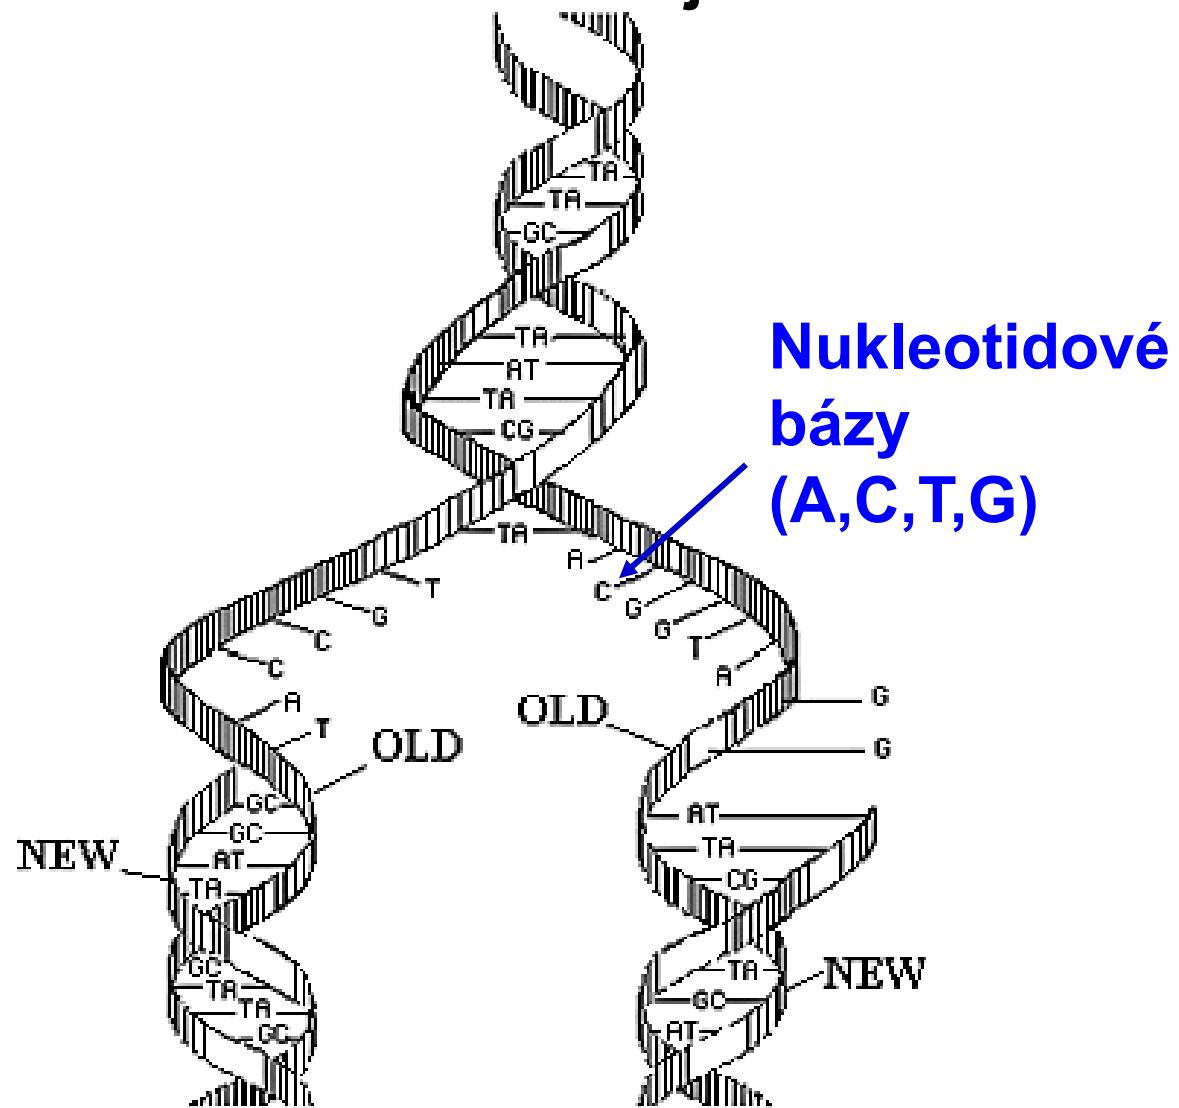
bunka



**DNK  
(DNA)**

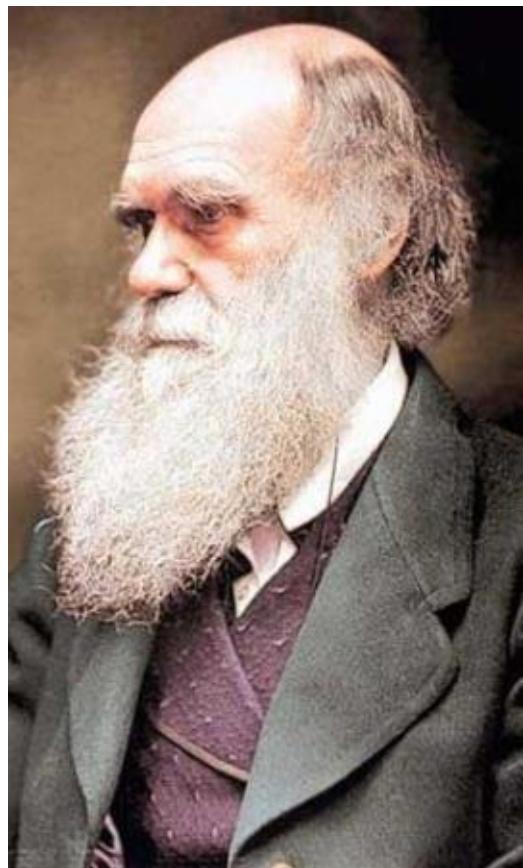
Človek má 3 mld. nukleotídových báz, 30 000 génov

**Genóm predstavuje kompletnú informáciu o stavbe tela a biologických vlastnostiach konkrétneho jedinca**

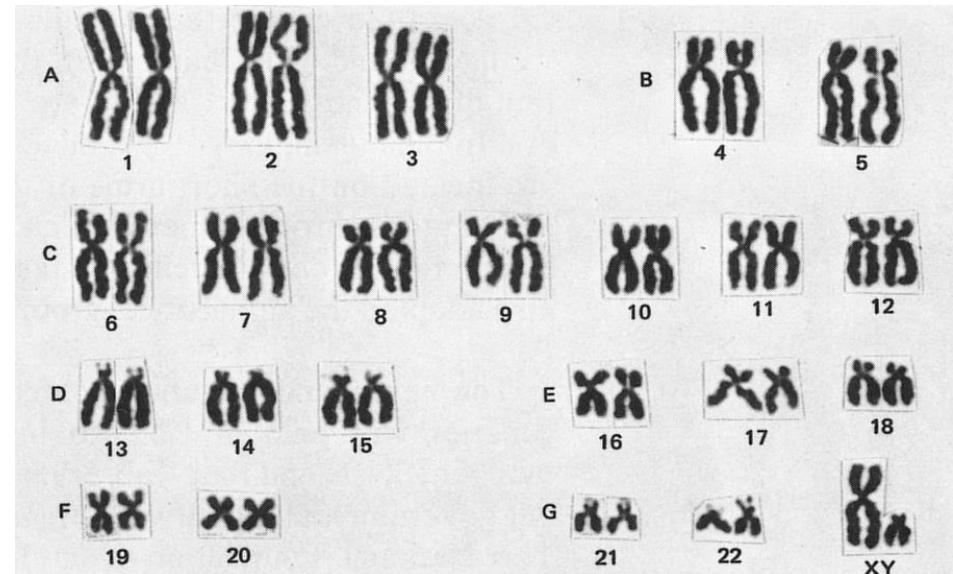


**Gény sú postupnosti nukleotídových báz, ktoré reprezentujú informácie o jednotlivých elementárnych vlastnostach jedinca**

# Charles Darwin



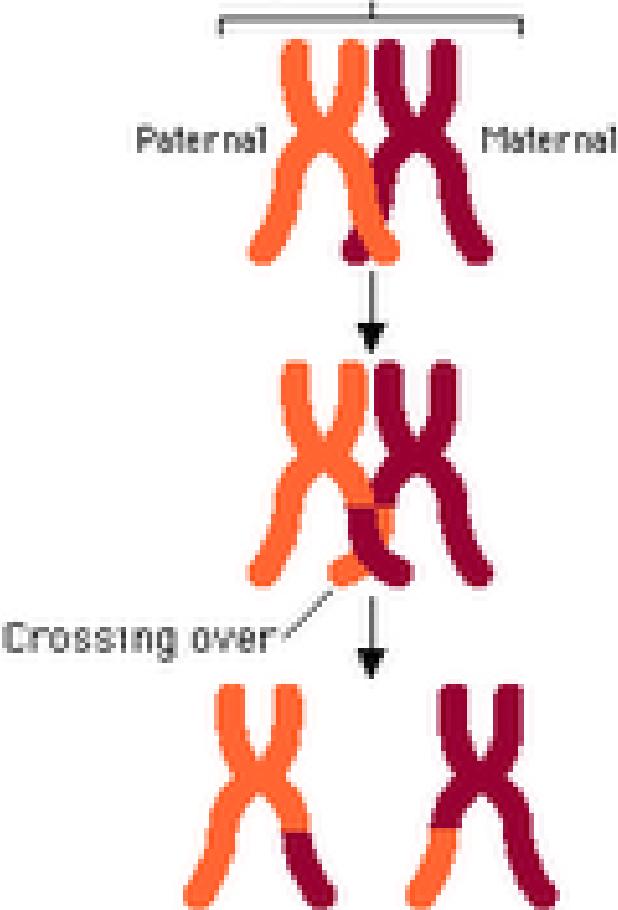
„genóm“



fenotyp

genotyp

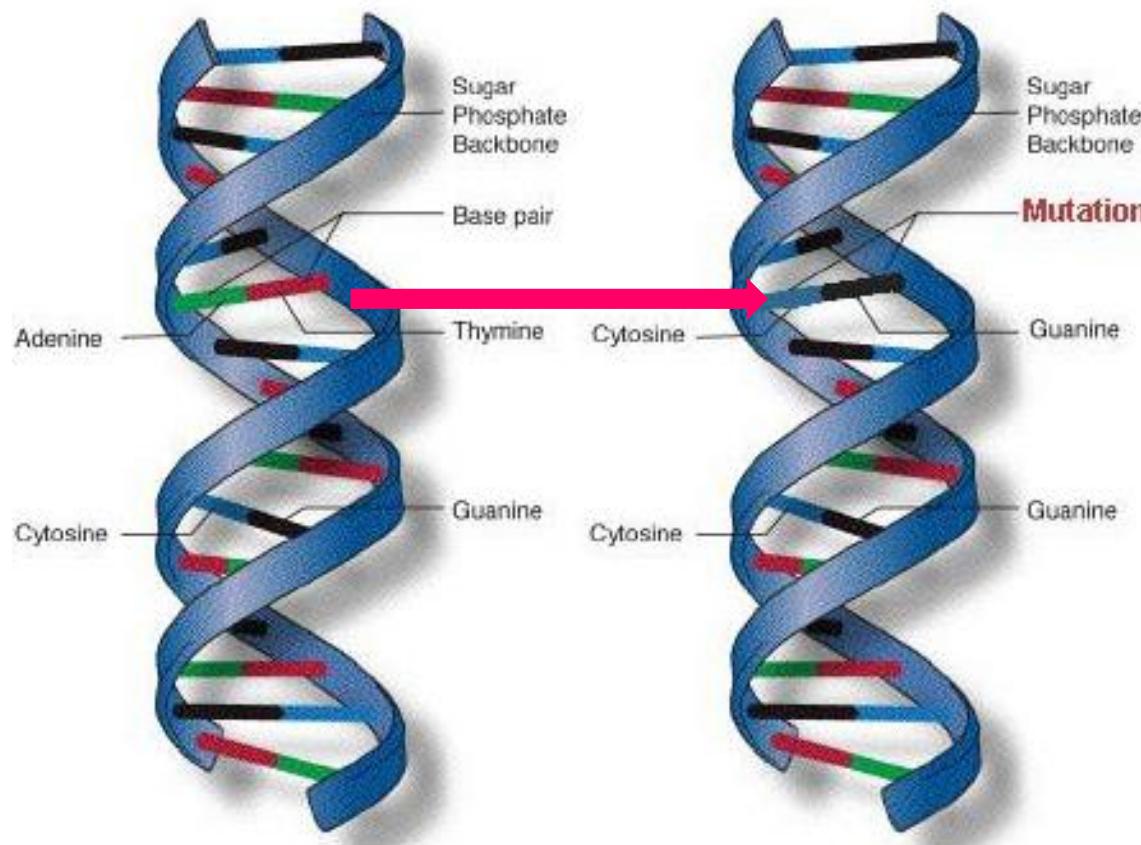
Synapsis: Pairing of homologous chromosomes



## Kríženie chromozómov dvoch rodičov – kombinácia génov rodičov u potomkov

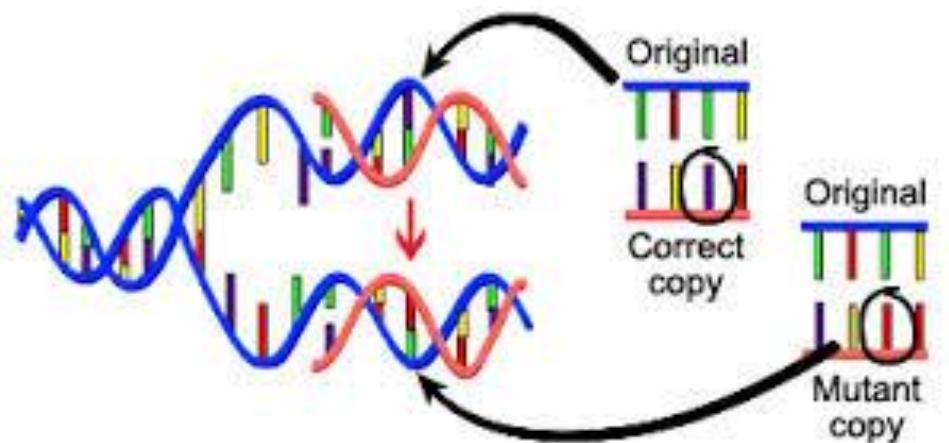
# Mutácia chromozómov

## Point Mutation



**Mutácia – náhodná zmena génov potomka oproti génom získaným od rodičov - nové vlastnosti.  
Vzniká pôsobením vonkajších vplyvov ako UV žiarenie, chemické vplyvy, tepelné vplyvy ...**

# Mutácia chromozómov



ACACTGGAACTGAGACACGGTCCAGTC  
GGGGAAACCTGAAAGCAGCAACGCCGGT  
TTAGGGAAAGAACCATGACGGTACCTAACG  
GTAATAACGGAGGGTGCAGCGTTACTCGG  
AAGTCTTTGTGA MUTATION AATCTA  
ATCTAGAGTGAGGGAGAGGCAGATGGAG  
GGAA TACCCATTGCGAAGGCAGATCTGCT  
AGCAAACAGGATTAGATAACCTGGTAGT  
CTAGTCACGGCAGTAATGCACCTAACGG

A B C D E F

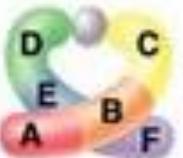
A C D E F

*DELETION*

A B C D E F

A B B C D E F

*DUPLICATION*

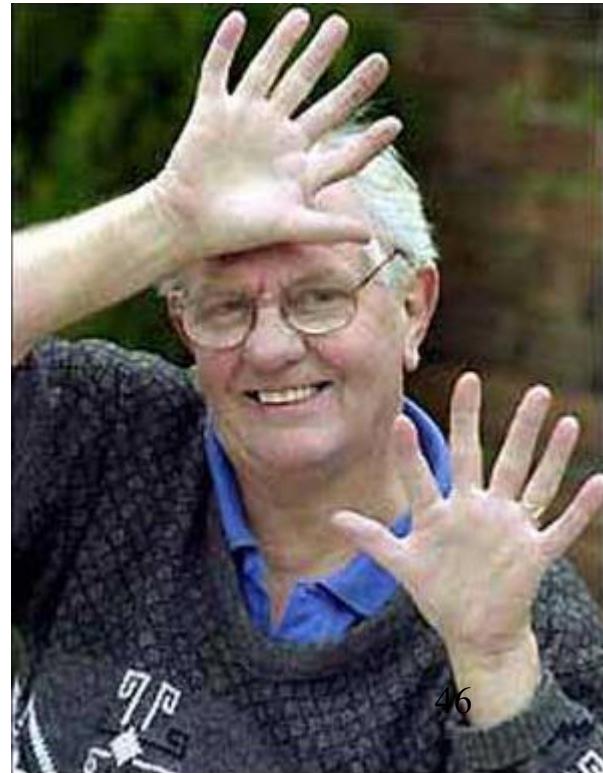


*INVERSION*

A B C D E J K L  
G H I E J K L

A B C J K L  
G H I D E F

*TRANSLOCATION*



**Boj o prežitie s predátormi, zápas o potravu, zápas o partnerov, snaha odolávať a prispôsobiť sa prírodným podmienkam → prežitie najschopnejších**

## Prirodzený výber



# Evolúcia



1 bunka - baktéria

6000 miliárd buniek - človek

**Napodobenie prirodzenej evolúcie pri  
počítačovom riešení praktických úloh:**

**Evolučné výpočtové prístupy  
(Evolučné algoritmy)**

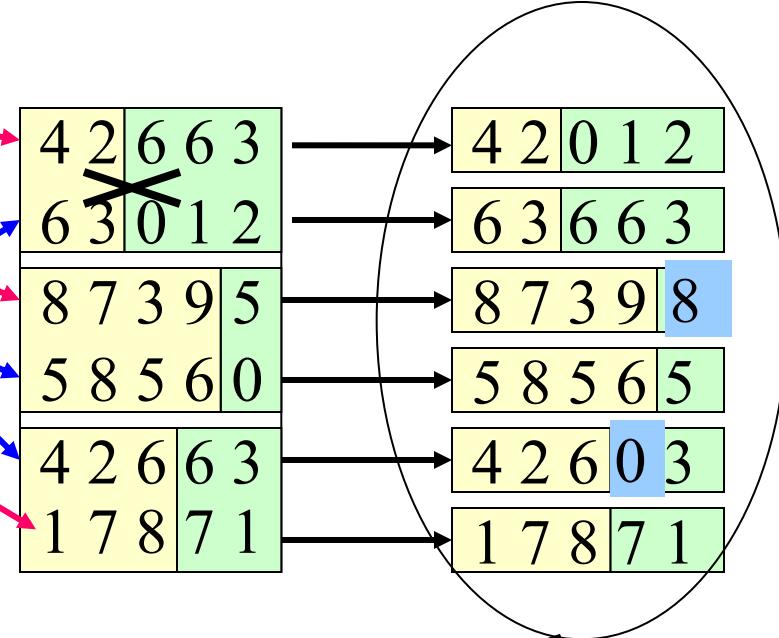
# **Reprezentanti evolučných výpočtových prístupov**

- Evolučné stratégie (numerické úlohy)
- Evolučné programovanie
- Genetické algoritmy
- Genetické programovanie (evolúcia štruktúr, programov)
- Diferenciálna evolúcia (numerické úlohy)
- Umelý imunitný systém
- Ďalšie (PSO, Kolónie mravcov, Kultúrne algoritmy, HSO, ... , umelý život)
- Iné ...

## Príklad:

„hádanie 5-ciferného čísla“  
**(1 2 3 4 5)**

5	9	2	0	1	0
4	2	6	6	3	1
8	7	3	9	5	2
5	8	5	6	0	0
1	7	8	7	1	1
0	1	9	0	9	0
6	3	0	1	2	0
2	7	5	6	1	0



8	7	3	9	5
4	2	6	6	3
4	2	0	1	2
6	3	6	6	3
8	7	3	9	8
5	8	5	6	5
4	2	6	0	3
1	7	8	7	1

## Algoritmus:

**nová skupina = 2 najlepšie jedince + modif( pracovná skupina)**

**pracovná skupina = 3 najlepšie jedince + 3 náhodné jedince**

5	9	2	0	1
4	2	6	6	3
8	7	3	9	5
5	8	5	6	0
1	7	8	7	1
0	1	9	0	9
6	3	0	1	2
2	7	5	6	1

0

4	2	6	6	3
6	3	0	1	2
8	7	3	9	5
5	8	5	6	0
1	7	8	7	1

1

8	7	3	9	5
5	8	5	6	0
1	7	8	7	1
0	1	9	0	9
6	3	0	1	2

2

5	8	5	6	0
1	7	8	7	1
0	1	9	0	9
6	3	0	1	2
2	7	5	6	1

0

1	7	8	7	1
0	1	9	0	9
6	3	0	1	2
2	7	5	6	1
1	7	8	7	1

1

0	1	9	0	9
6	3	0	1	2
2	7	5	6	1
1	7	8	7	1
0	1	9	0	9

0

6	3	0	1	2
2	7	5	6	1
1	7	8	7	1
0	1	9	0	9
6	3	0	1	2

0

2	7	5	6	1
1	7	8	7	1
0	1	9	0	9
6	3	0	1	2
2	7	5	6	1

0

4	2	6	6	3
6	3	0	1	2
8	7	3	9	5
5	8	5	6	0
1	7	8	7	1

4	2	0	1	2
6	3	6	6	3
8	7	3	9	8
5	8	5	6	5
4	2	6	0	1

6	3	6	6	3
8	7	3	9	8
5	8	5	6	5
4	2	6	0	1
1	7	8	6	3

8	7	3	9	8
5	8	5	6	5
4	2	6	0	1
1	7	8	6	3
1	7	8	6	3

5	8	5	6	5
4	2	6	0	1
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3

4	2	6	0	1
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3

1	7	8	6	3
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3

2	7	5	6	3
1	7	3	9	8
1	5	8	5	6
1	4	2	6	0
1	1	7	8	6

2

1

1

1

1

1

1

1

1

1	7	8	6	3
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3
1	7	8	6	3

53

C1

C0

8	7	3	9	5	2
4	2	6	6	3	1
4	2	0	6	3	1
4	2	8	1	2	1
1	7	3	9	8	2
8	7	8	6	0	0
8	7	3	0	1	1
4	2	6	4	5	3

17398  
42645  
42063  
87860  
87860  
87395  
87395

12645  
47398  
42060  
87163  
87395  
87860

C2

4	2	6	4	5	3
8	7	3	9	5	2
1	2	6	4	5	4
4	7	3	9	8	1
4	2	0	6	0	1
8	7	1	6	3	0
8	7	3	9	5	2
8	7	8	6	0	0

42060  
42645  
42645  
87395  
87860  
12645

42065  
42640  
02795  
87645  
87645  
12860

C3

1 2 6 4 5	4
4 2 6 4 5	3
4 2 0 6 5	2
4 2 6 4 0	2
0 2 7 9 5	2
8 7 6 4 5	2
8 7 6 4 5	2
1 2 8 6 0	2

Diagram illustrating two permutations (C4 and C5) and their transitions:

**C4:**

1 2 8 6 0
4 2 6 4 5
1 2 6 4 5
0 2 7 9 5
8 7 6 4 5
8 7 6 4 5
4 2 0 6 5

**C5:**

8 7 6 6 5
4 2 8 6 0
4 2 6 4 5
1 2 6 4 5
1 2 7 9 5
4 2 3 4 5

C4

1 2 6 4 5	4
4 2 6 4 5	3
1 2 6 4 8	3
4 2 8 6 0	1
1 2 7 9 5	3
0 2 6 4 5	3
8 7 6 6 5	1
4 2 3 4 5	4

Diagram illustrating two permutations (C4 and C5) and their transitions:

**C4:**

1 2 8 6 0
4 2 6 4 5
1 2 6 4 5
0 2 7 9 5
8 7 6 4 5
8 7 6 4 5
4 2 0 6 5

**C5:**

8 7 6 6 5
4 2 8 6 0
4 2 6 4 5
1 2 6 4 5
1 2 7 9 5
4 2 3 4 5

C5

## **1.3 Základné objekty a pojmy v GA**

- Ret'azec (chromozóm)
- Gén
- Populácia
- Generácia
- Účelová funkcia (Fitness)

# Ret'azec

je do postupnosti čísel alebo symbolov zakódovaná množina parametrov optimalizovaného objektu

- **binárny ret'azec :**

[ 1 0 0 1 1 1 1 0 ]

- **celočíselný ret'azec :**

[ 2 7 7 9 0 5 3 ]

- **reálne-číselný ret'azec :**

[ 7.1 2 10 0.02 258 99.9 ]

- **symbolový ret'azec :**

[ NB Z PS PM modrý zásaditý ]

- a ich kombinácie

# Príklady ret'azcov

- Počty  $x_i$  vyrobených výrobkov  $v_1, v_2, \dots, v_n$   
 $r = [x_1, x_2, x_3, \dots, x_n]$
- Konštrukčné parametre robota  $p_1, p_2, \dots, p_n$   
 $r = [p_1, p_2, p_3, \dots, p_n]$
- Parametre PID regulátora  
 $r = [P, I, D]$

# Permutačné kódovanie ret'azcov

Spôsob zakódovania takého typu ret'azcov, ktoré reprezentujú potenciálne riešenia úloh hľadania:

- optimálneho poradia prvkov
- optimálnej postupnosti operácií a pod.

gény ret'azcov sú poradové čísla  
(celé čísla od 1 do N)

[ 2 5 3 6 7 1 4 8 ]

[ 1 2 3 4 8 7 6 5 ]



# **Príklad ret'azcov s permutačným kódovaním**

- Poradie vykonaných výrobných operácií  
 $O_1, O_2, \dots, O_n$   
 $r = [2, 5, \dots, 7]$
- Poradie vybavovania zákazníkov
- $r = [1, 15, \dots, 7]$
- Poradie prejdených miest

# **Populácia**

je skupina (vhodnej veľkosti) reťazcov v danej časovej etape resp. v danom výpočtovom cykle (v danej “generácii”)

***Príklad celočíselnej populácie:***

[	1	2	3	4	5	6	7	
	5	8	9	3	0	1	3	
	8	1	1	1	0	2	7	
	...							
	8	9	1	9	9	0	6	]

# **Účelová funkcia**

## **(kriteriálna f., objective.f.)**

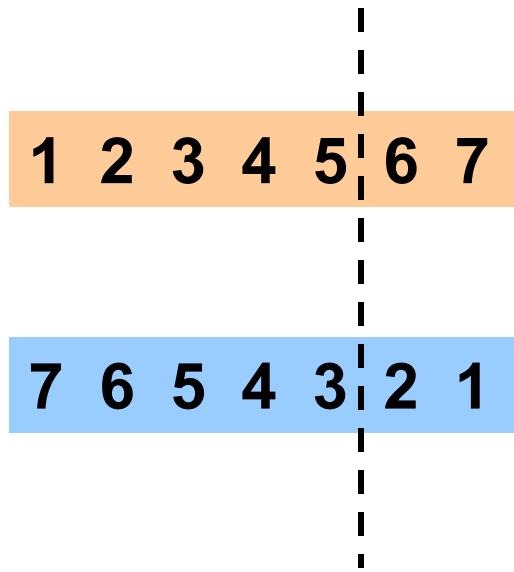
- predstavuje samotnú podstatu optimalizovaného problému
- vyjadruje mieru vhodnosti daného potenciálneho riešenia a cieľom je nájsť riešenie s jej minimálnou resp. maximálnou hodnotou
- jej výstupnými hodnotami sú skalárne (obyčajne reálne-číselné) hodnoty

**„Fitness“ (funkcia)** – účelová funkcia v terminológii GA,  
my budeme fitness minimalizovať (GA toolbox Matlab)

## **1.4 Základné genetické operácie**

- Kríženie
- Mutácia
- Výber (selekcia)
- kombinované

## Kríženie

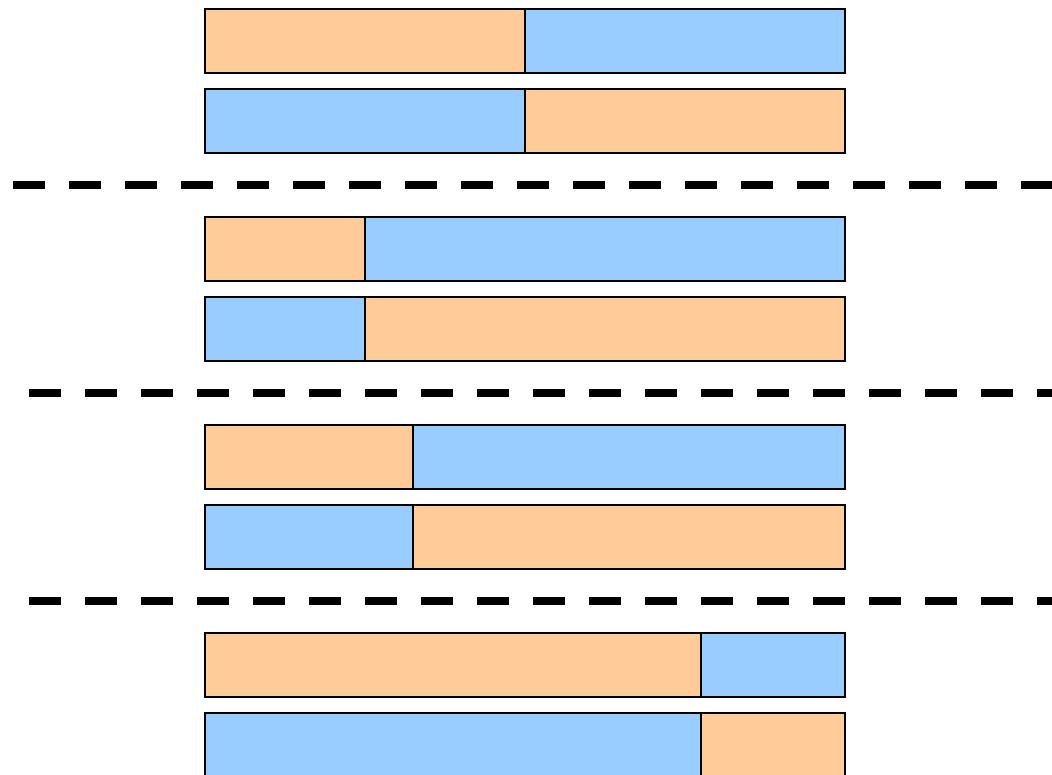


rodičovské ret'azce



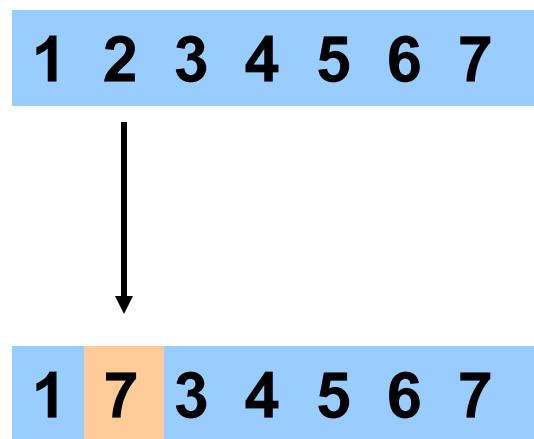
potomkovské ret'azce

# Kríženie v celej populácii

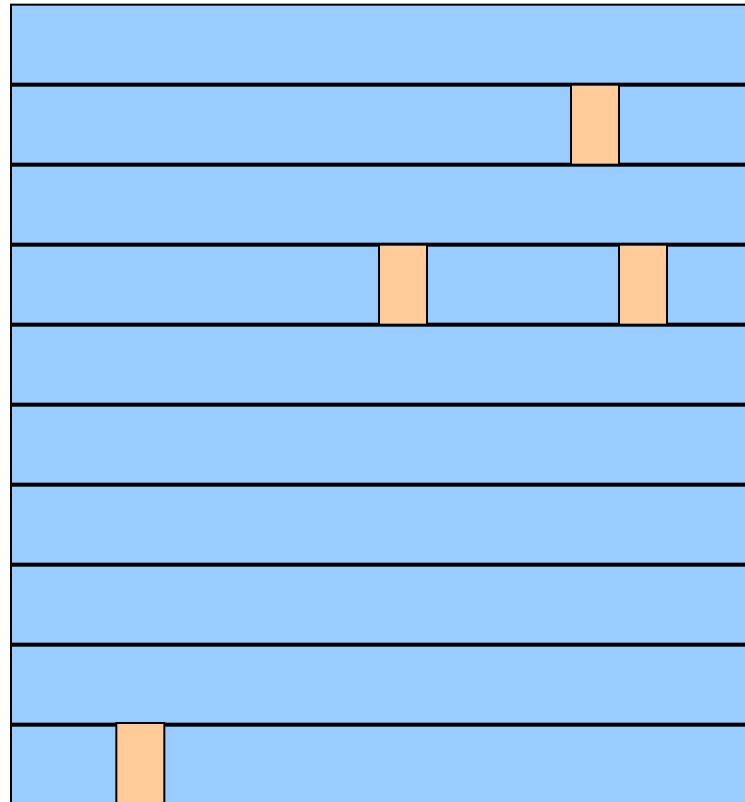


• • •

## Mutácia



# Mutácia v rámci populácie



**Pravdepodobnosť mutácie jedného génu v rámci celej populácie je zvyčajne od 0.1 – 10%**

# Mutácie rôznych typov ret'azcov

1 1 0 1 0 0 0 1 0

1 1 0 1 0 1 0 1 0

7.2 5.03 1999 0.001

7.2 17.5 1999 0.001

O<sub>2</sub> H CO<sub>2</sub> S Zn Fe H<sub>2</sub>SO<sub>4</sub>

O<sub>2</sub> H CO<sub>2</sub> S Si Fe H<sub>2</sub>SO<sub>4</sub>

## Výber

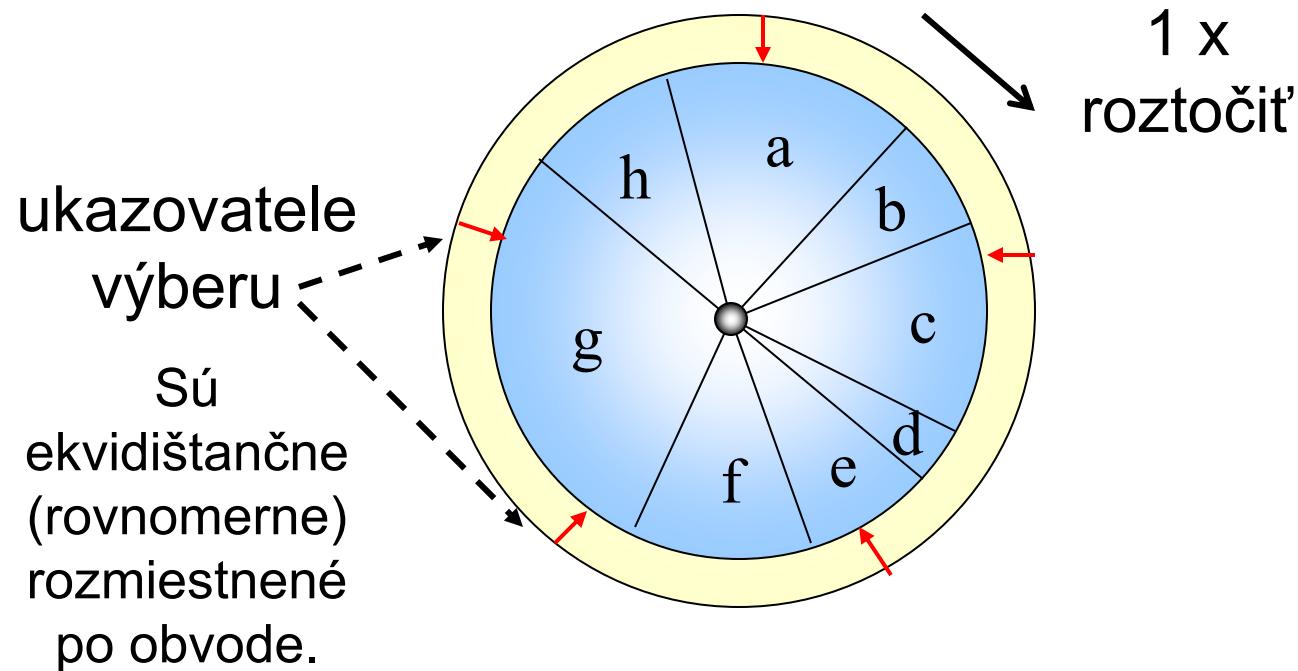
Úlohou výberu je:

- vybrať potrebný počet ret'azcov (rodičov), ktoré budú modifikované pomocou genetických operácií,
- vybrať ret'azce, ktoré sa nezmenené dostanú do novej generácie.

Existuje viacero typov výberu.

Pri výbere platí: úspešnejšie ret'azce majú väčšiu pravdepodobnosť byť vybrané než menej úspešné.

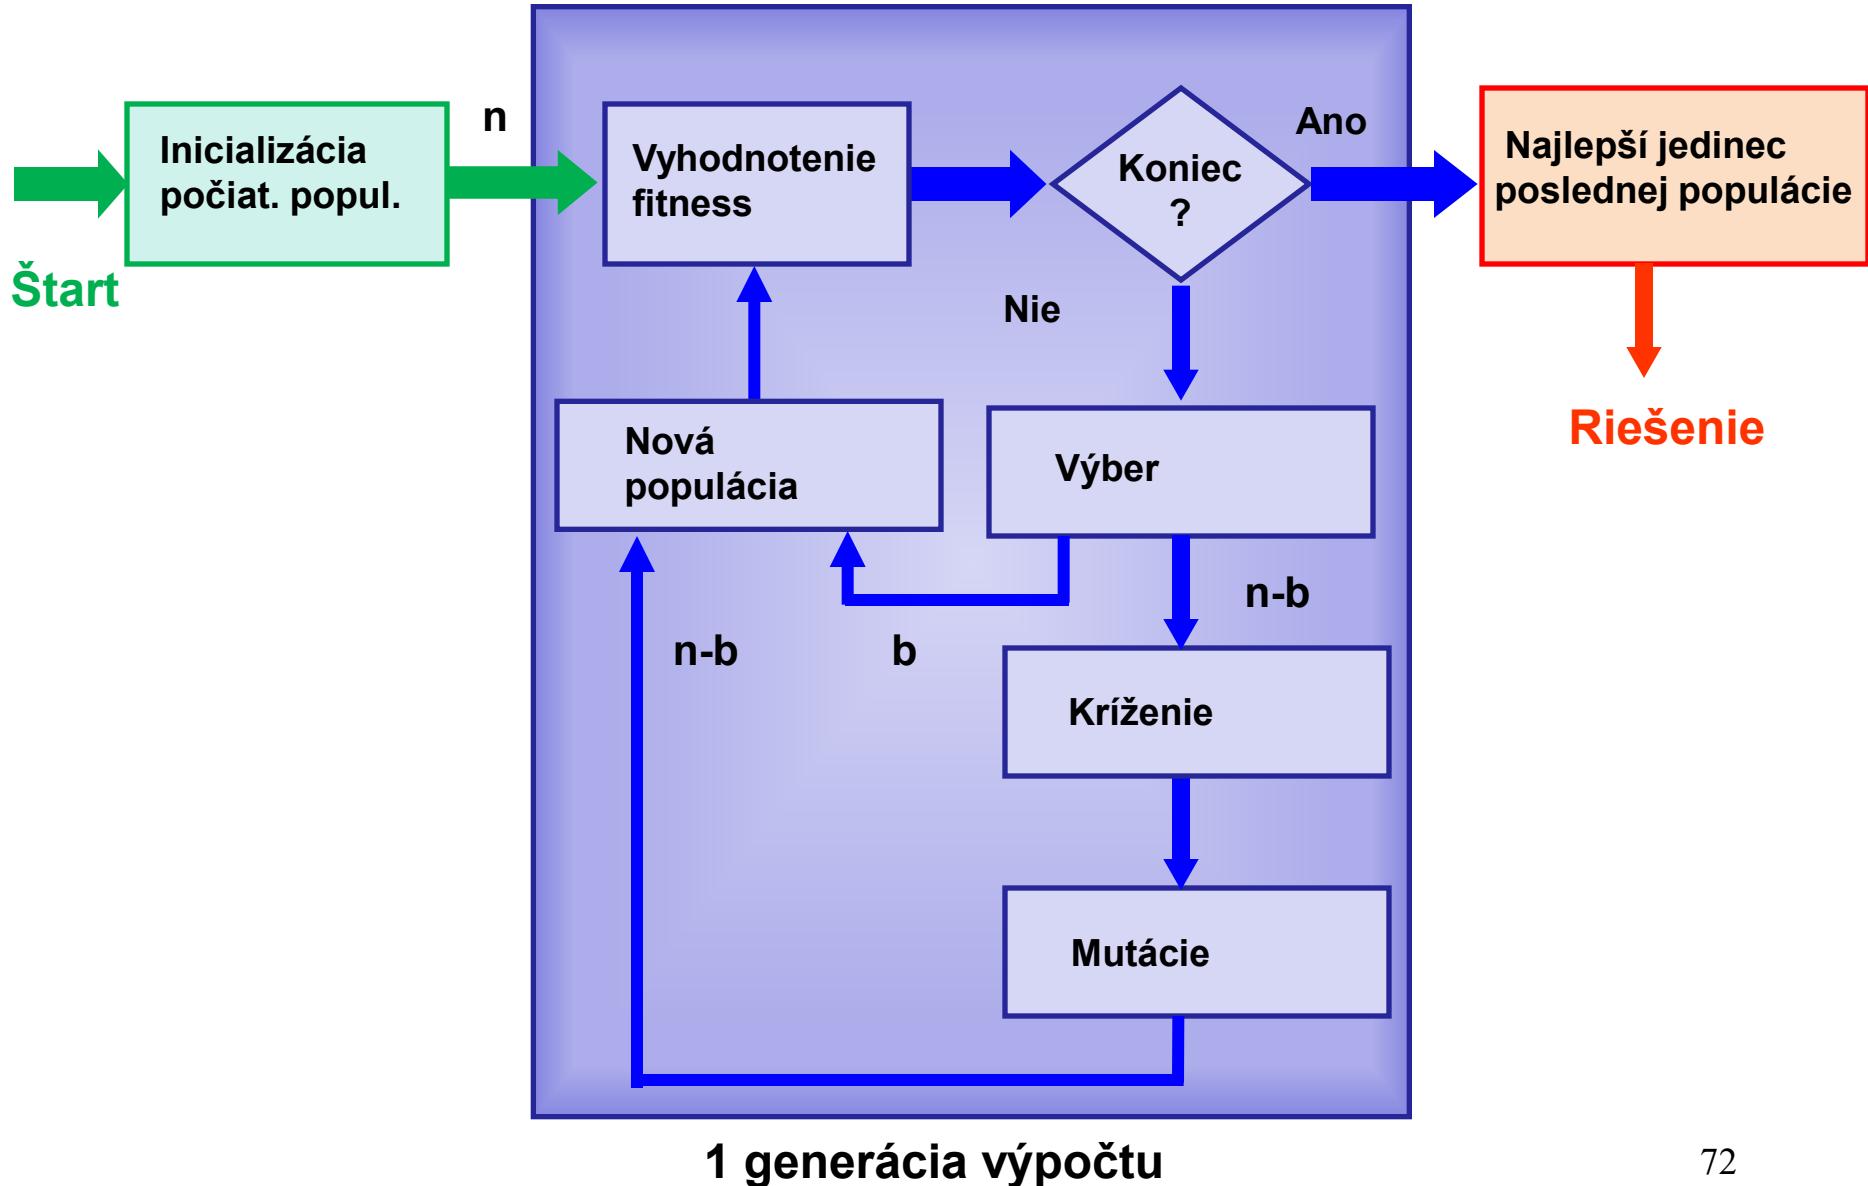
# Rovnomerný váhovaný ruletový výber (selsus.m)



Ukážu  
vybraných  
jedincov.

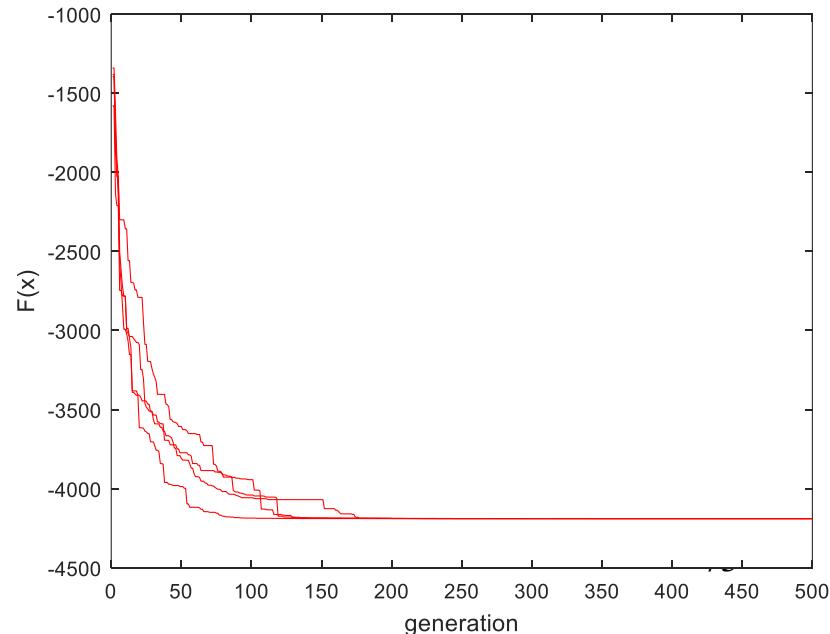
## **1.5 Genetický algoritmus (GA)**

# Genetický algoritmus



# Ukončovacie podmienky GA

- testovanie splnenia vopred definovaných podmienok
- stagnácia hodnoty účelovej funkcie
- podobnosť (identita) mnohých jednícov v populácii
- ukončenie predpísaného počtu generácií (cyklov algoritmu)



# Zjednodušene môžeme povedať'

- Podstatou optimalizácie pomocou GA je náhodné kombinovanie prvkov ret'azcov tak, aby bola maximalizovaná ich účelová funkcia.
- Najhoršie kombinácie sú vylučované, najlepšie sú posúvané do ďalších generácií, kde sú kombinované s inými úspešnými ret'azcami (krížené) alebo náhodne menené (mutované).
- Ak sa takýto cyklus mnohokrát opakuje, je možné sa priblížiť ku globálnemu optimu.

**Príklad:** hľadanie globálneho minima Schwefelovej funkcie použitím genetického algoritmu  
**(cvičenia, úloha 2)**