Iné typy
umelých neurónových sietí

Neurónové siete s radiálnymi bázovými funkciami (RBF - siete)

RBF -siete

- **Obsahujú tri vrstvy neurónov**
- **Vstupná vrstva distribuuje vstupné signály cez váhované spoje do neurónov skrytej vrstvy**
- **Skrytá vrstva realizuje nelineárnu transformáciu**
- **Výstupná vrstva uskutočňuje pre každý výstup siete iba lineárnu kombináciu výstupov neurónov skrytej vrstvy**

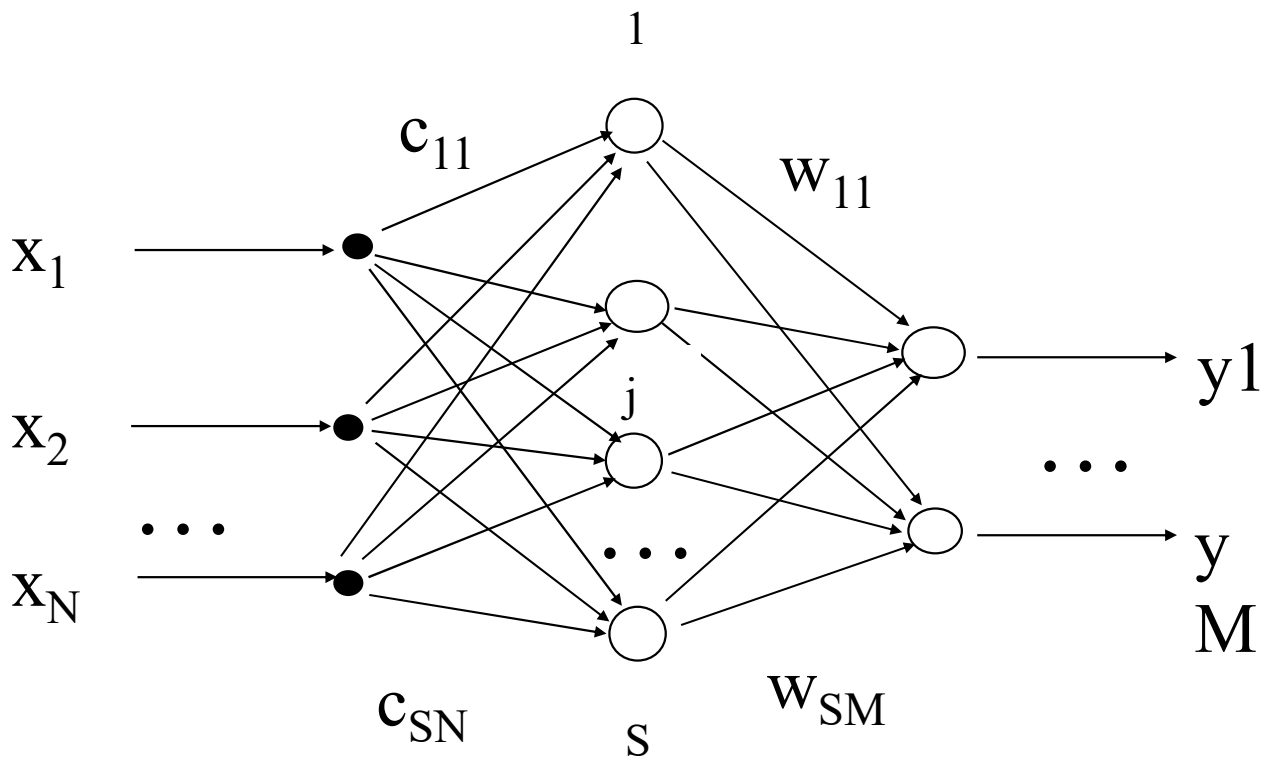

j-ty neurón skrytej vrstvy

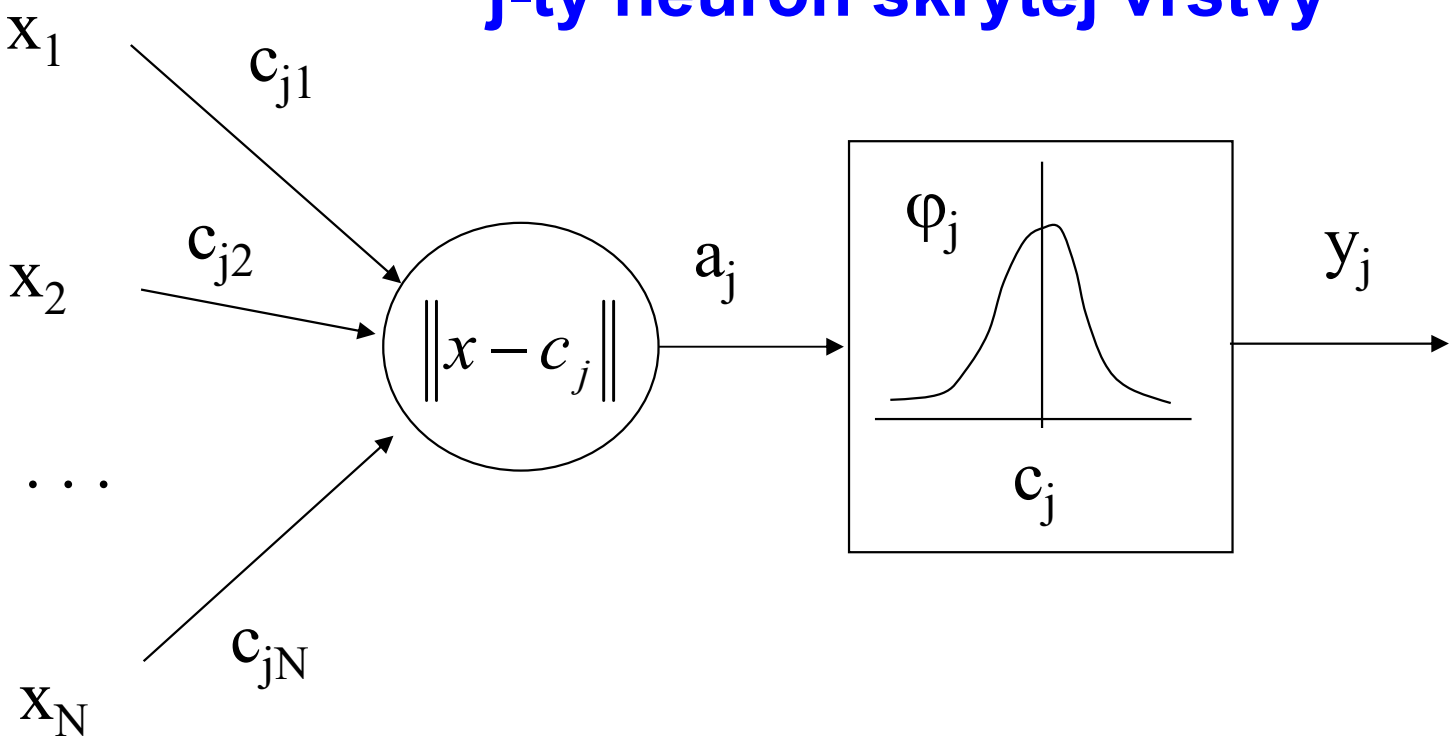

- **Vstupný vektor x je v danom kroku privedený cez váhy c_{ji} do vstupnej časti neurónu**
- **Je vypočítaná norma (najčastejšie euklidovská), čo je vzdialenosť váhovaných vstupov od "centra" radiálnej bázovej funkcie c_j.**
- **Transformačná funkcia neurónu je spravidla symetrická n-rozmerná nelineárna funkcia so stredom v bode c_j. Stred c_j pritom predstavuje bod v priestore so súradnicami [c_{j1}, ... , c_{jN}] , kde i=1,2,...,N je počet vstupov a j=1,2,...,S je počet "RBF" neurónov v skrytej vrstve.**

Typicky používanou transformačnou funkciou je gaussovská f. v tvare

$$\varphi(a) = \exp\left(-\frac{a^2}{2\sigma^2}\right) \qquad a = \left\| x - c_j \right\|$$

Niekedy sa používa aj tzv. “thin-plate-spline” funkcia

$$\varphi(a) = a^2 \ln(a)$$

RBF sieť s N vstupmi, S neurónmi v skrytej vrstve a M výstupmi dokáže aproximovať ľubovoľné nelineárne zobrazenie cez priestory $R^N \rightarrow R^M$, ktoré možno vyjadriť v tvare

$$y_k(x) = \sum_{j=1}^{S} w_{jk} \varphi_j(\|x - c_j\|) \qquad k = 1,2,\ldots,M$$

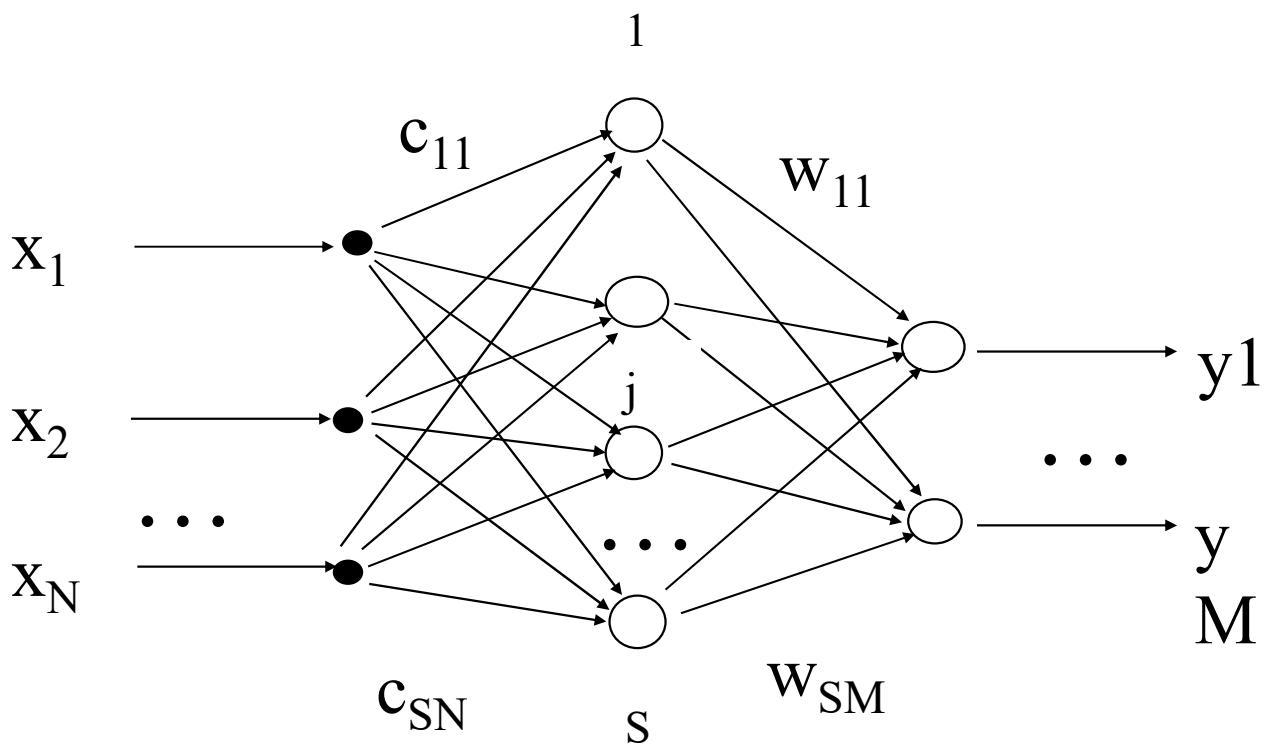

Trénovanie RBF siete

<u>1.krok</u> – určenie vstupných váh c_{ji} , čo zodpovedá polohe centier skrytých neurónov. Triviálne riešenia sú náhodný výber alebo rovnomerný výber bodov vo vstupnom priestore. Možno však použiť aj iné, účinnejšie algoritmy ako napr. minimalizáciu celkovej sumy vzdialeností medzi centrami a vstupnými bodmi x.

<u>2.krok</u> – nastavenie pomocných parametrov RBF siete, napr. parametrov σ (šírka) radiálnych bázových funkcií pomocou minimalizácie vhodne zvolenej krit. f. alebo heuristicky. Šírka jednotlivých RBF má vplyv na zovšeobecňovaciu schopnosť siete.

<u>3. krok</u> – nastavenie výstuných váh w_{jk} minimalizáciou krit. f.

$$E(w) = \tfrac{1}{2}\sum_{k=1}^{N}\left(\left\|d_k - y(x_k)\right\|^2\right)$$

ktorá minimalizuje odchýlku výstupu siete oproti predlohe $D=\{d_k\}^{k=1,2..,N}$.

D je množina vstupno/výstupných (vektorových) dvojíc a N je počet aproximovaných bodov, ktorý sa rovná počtu skrytých neurónov.

Rozdiely medzi sieťami RBF a MLP

- Perceptrón môže používať principiálne viac skrytých vrstiev, RBF sieť iba 1
- Každý neurón RBF zvyčajne máva svoje vlastné parametre
- Argumentom aktivačnej funkcie RBF je (euklidovská) norma vstupného vektora od centra RBF funkcie
- Na výstupnej hodnote perceptrónovej siete sa podieľa mnoho neurónov (alebo všetky), pri RBF pre daný vstup sú aktívne iba niektoré (tzv. „lokálne neuróny“)
- Perceptrónová sieť dokáže generalizovať aj v regiónoch vstupného priestoru, v ktorých je k dispozícii len málo trénovacích dát. RBF nato, aby dokázala dostatočne dobre zovšeobecňovať potrebuje dostatočne vhodne „rozvrstvený“ súbor trénovacích bodov a pre každý bod jeden RBF neurón.
- Trénovanie perceptrónovej siete je výpočtovo náročné a zdĺhavé, trénovanie RBF siete je rýchle.

Kohonenove siete
(Samoorganizujúce sa mapy –SOM)

Kohonenová sieť

<u>Typ siete</u> : Samoorganizujúca sieť nepotrebuje učiteľa k trénovaniu

- Počet vstupov do neurónu je rovný počtu vstupov do Kohonenovej siete
- váhy vstupov slúžia k zakódovaniu vzorov
- neuróny nemajú prenosovú funkciu
- každý neurón je priamo aj výstupom (výstupné neuróny nie sú vzájomne prepojené, prepojenie je len so susednými neurónmi)
- počet výstupov je rovný počtu neurónov
- *Matematicky,* každý neurón počíta odchýlku predložených vzorov od vzoru zakódovaného vo váhach

$$d = \sum_{i=0}^{N-1} \left[x_i(t) - w_i(t) \right]^2$$

- počet neurónov je funkciou aplikácie (od 10 x 10 až do 30 x 30 neurónov)

Kohonenova sieť - topológia

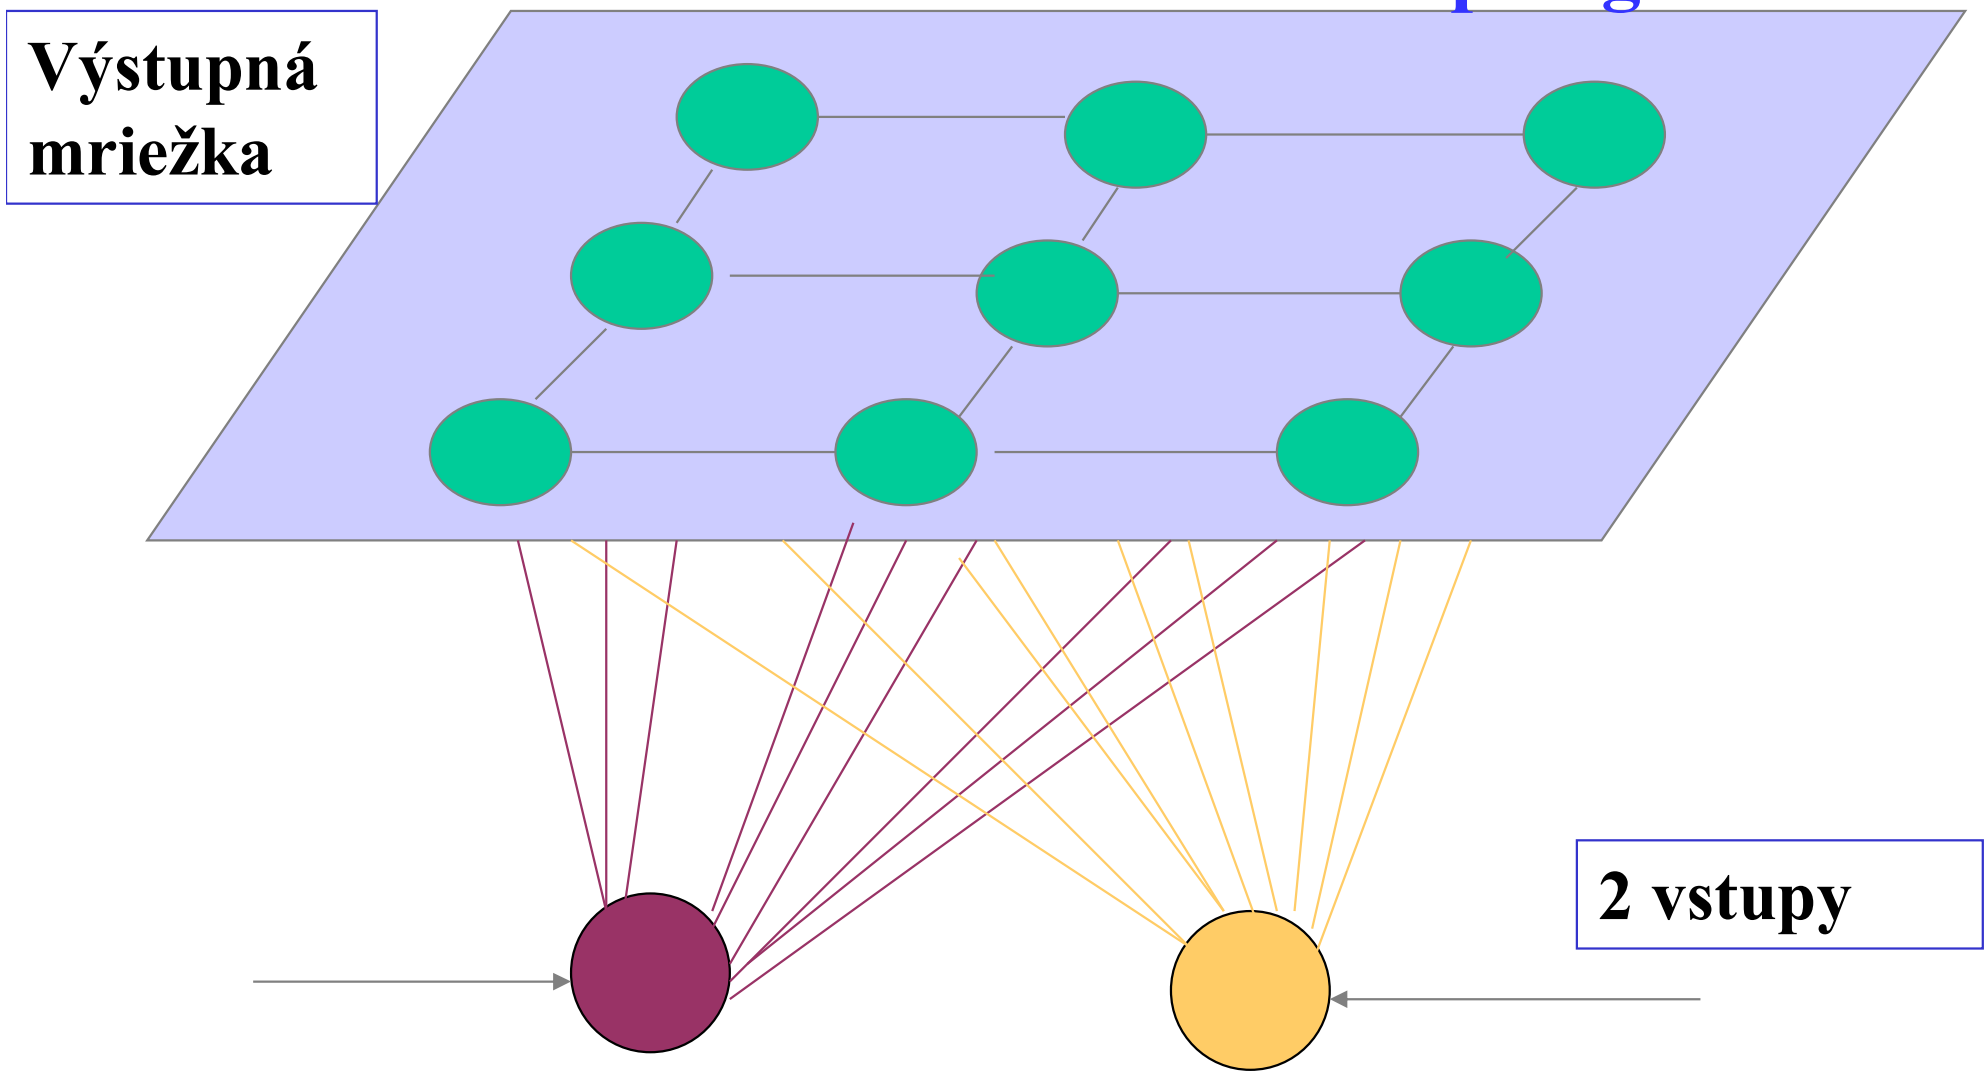

-algoritmus učenia má za cieľ usporiadať neuróny v mriežke do určitých oblastí tak, aby boli schopné klasifikovať predložené údaje.

-proces účenia je adaptívny, iteračný výpočtový proces

Algoritmus účenia KS

•1.krok : Inicializácia-nastavenie váh w_{ij}, pre všetky spoje z N vstupov do M výstupných neurónov

$$0 \le i \le N-1$$
$$0 \le j \le M-1$$

počiatočné hodnoty váh nastavujeme napr. náhodným algoritmom (rands)

•parametre účenia $\eta(0)$ (rýchlosť účenia) nastavíme na začiatku na hodnotu blízku 1, pričom

$$0 \le \eta(t) \le 1$$

•2.krok predloženie vzorov na vstup

$$X(t) = \{x_0(t), x_1(t), \ldots, x_{N-1}(t)\}$$

•výpočet vzdialeností vzorov medzi predloženým vzorom a všetkými výstupmi

$$d_j = \sum_{i=0}^{N-1} \left[x_i(t) - w_{ij}(t)\right]^2$$

kde $x_i(t)$ sú prvky vstupného vzoru a w_{ij} sú váhy medzi i-tým vstupom a j-tým výstupným neurónom v ktorých sú zakodované vzory

4. Krok: Výber najviac podobného neurónu podľa vzťahu

$$d^*_j = \min_j(d_j)$$

5.Krok: Modifikácia - Adaptácia váh, korekcia váh pre j*-ty neurón a jeho okolie (susediace neuróny) podľa vzťahu:

$$w_{ij}(t+1) = w_{ij}(t) + \eta(t)\left[x_i(t) - w_{ij}(t)\right]$$

kde j sú všetky neuróny ležiace v okolí $N^*_j(t)$

6. Krok Pokračovanie- všetkými vzormi na vstupe, všetkými trénovacími krokmi, test podľa presnosti, *if áno then krok 2 else end*

Poznámka:

- počiatočné nastavenie váh sa realizuje náhodne-každý neurón má svoj vlastný originálny váhový vektor

- koeficient účenia (rýchlosť učenia) sa najprv nastavuje na hodnotu jedna a behom procesu učenia klesá k nule(lineárne, exponenciálne, hyperbolic.)

- voľba okolia - pre každý neurón na začiatku sú to všetky neuróny v mriežke, postupne sa okolie redukuje, mimimálne okolie je jeden neurón

- víťazným neurónom je ten, ktorého váhový vektor odpovedá najviac vstupnému vzoru, pre takýto neurón sa budú adaptovať váhy

- výberom určitých víťazných neurónov - zvýšenie citlivosti reagovať aj na nenatrénovaný vzor-princíp zovšeobecnenia

Prevádzkovanie KS po natrénovaní

1. Krok - vstup nového neznámeho vzoru na vstupy do siete

$$X(t)=\{x_0,x_1,\ldots,x_{N-1}\}$$

2. Krok - výpočet najbližšieho vzoru pomocou vzťahu

$$d_j = \sum_{i=0}^{N-1} \left[x_i(t) - w_{ij}(t)\right]^2$$

a výber takého neurónu, ktorý splňa podmienku $d_j^* = \min_j(d_j)$

Kohonenova sieť – štruktúra s viacerými vstupmi

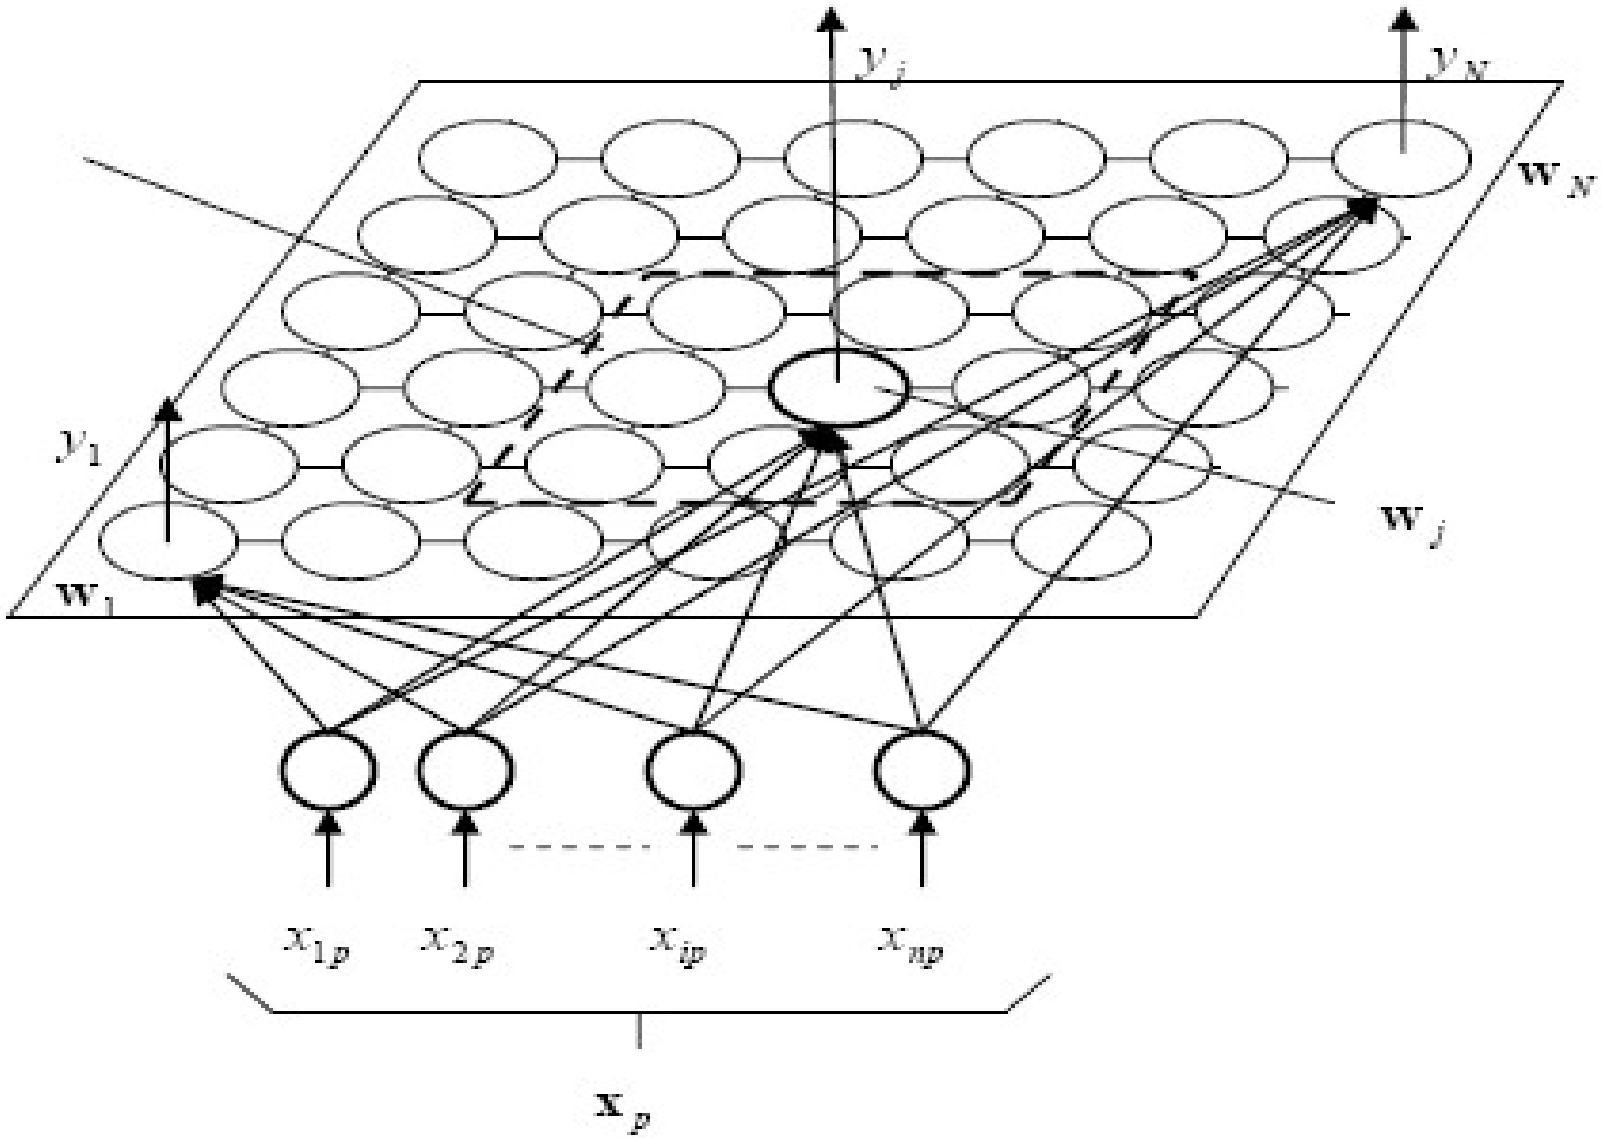

Kohonenova sieť – redukcia kroku učenia a okolia

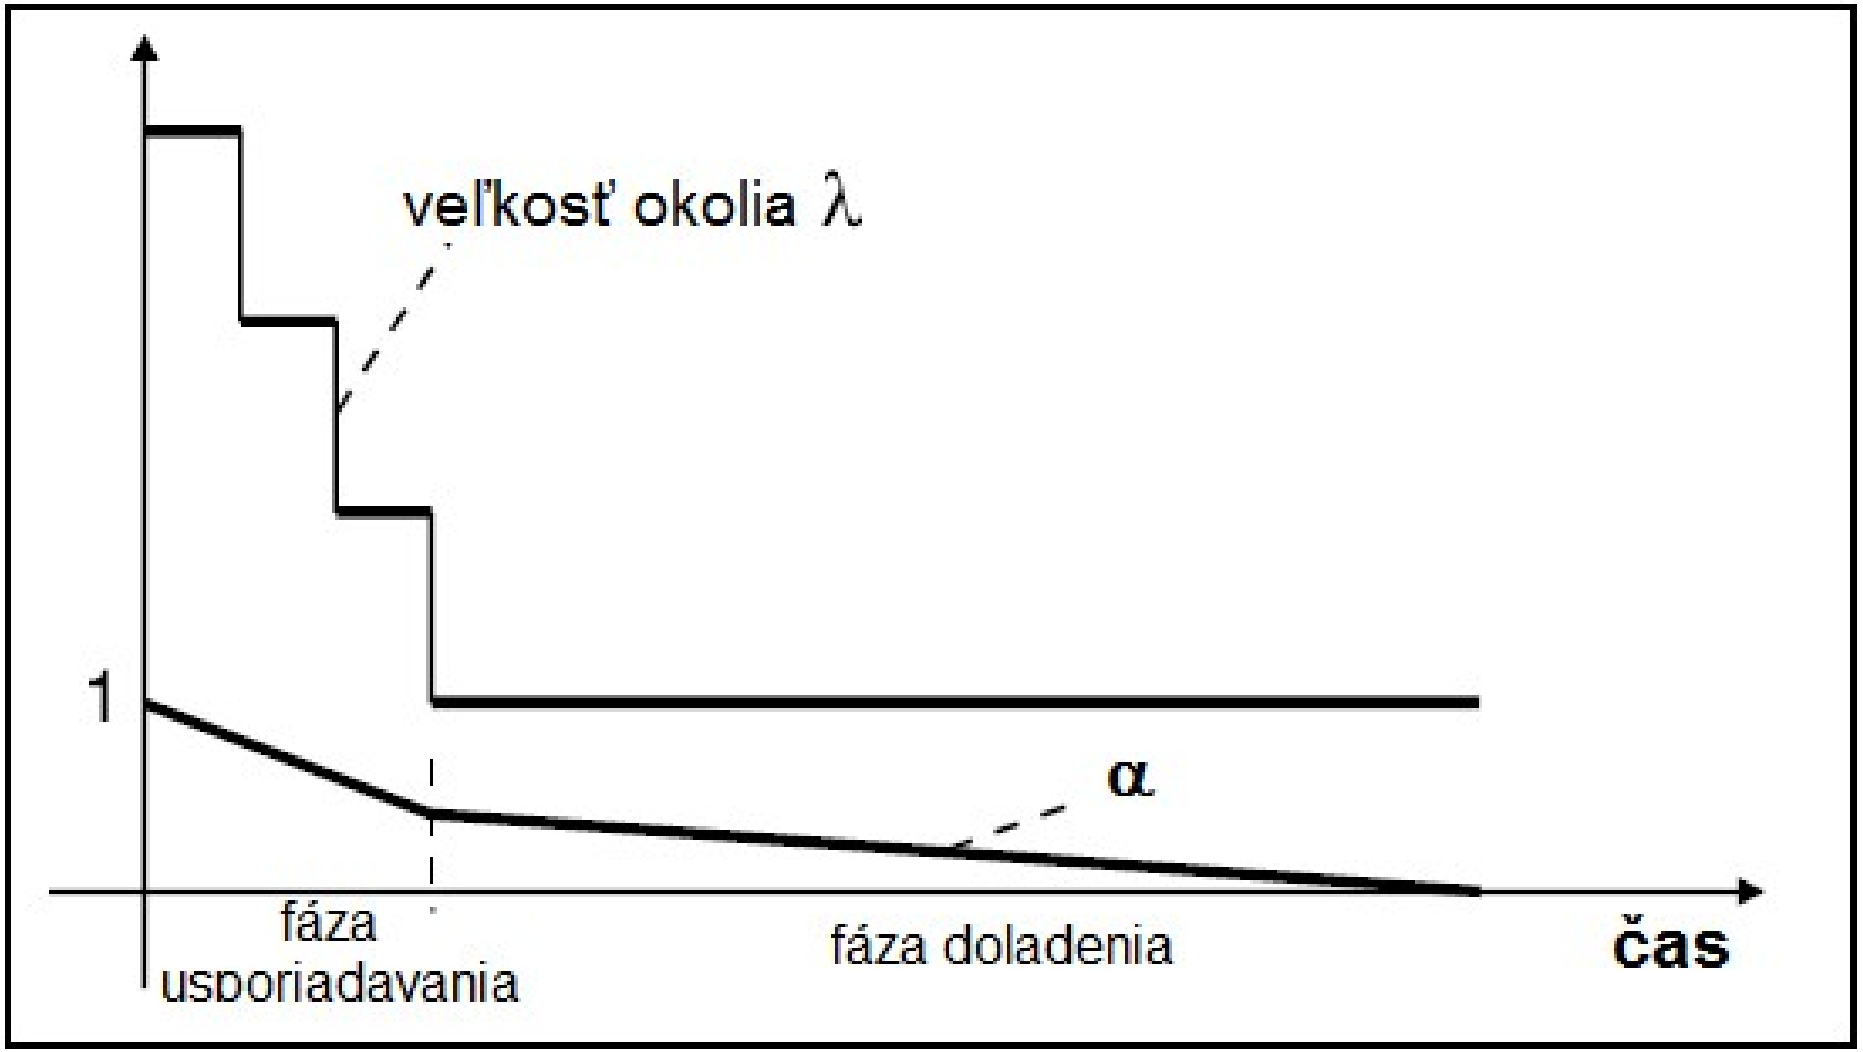

Kohonenova sieť – priebeh učenia

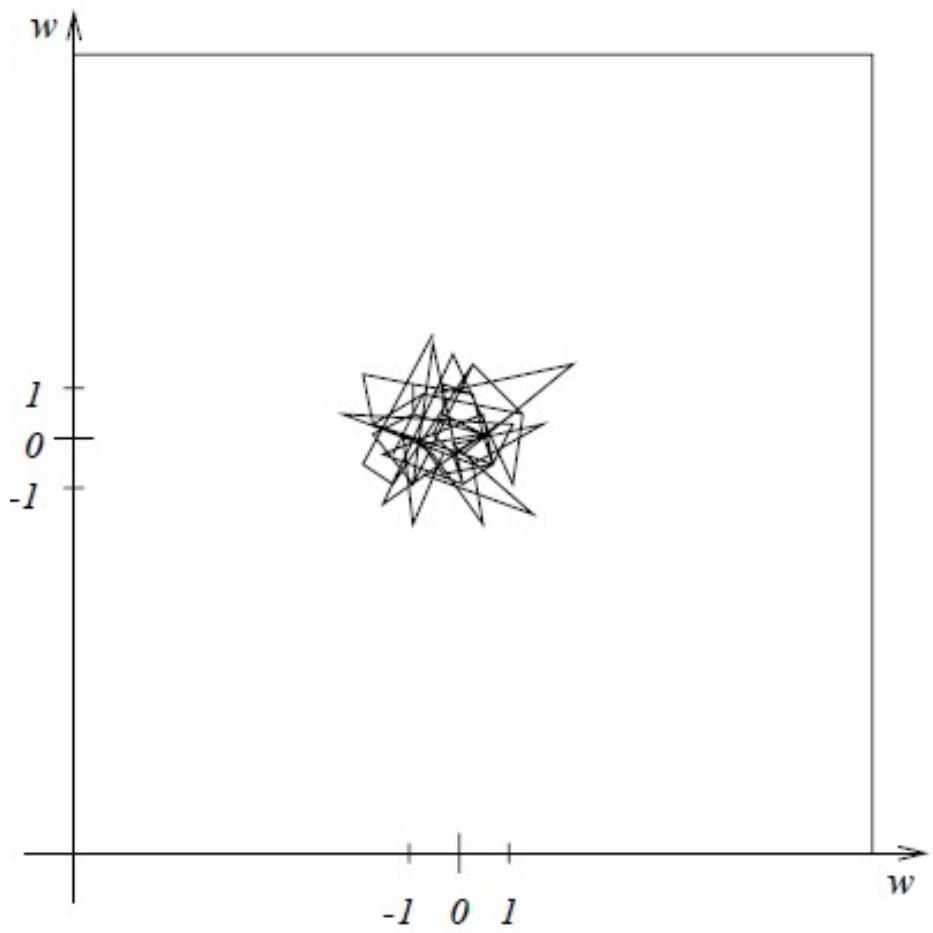

Inicializácia váh:

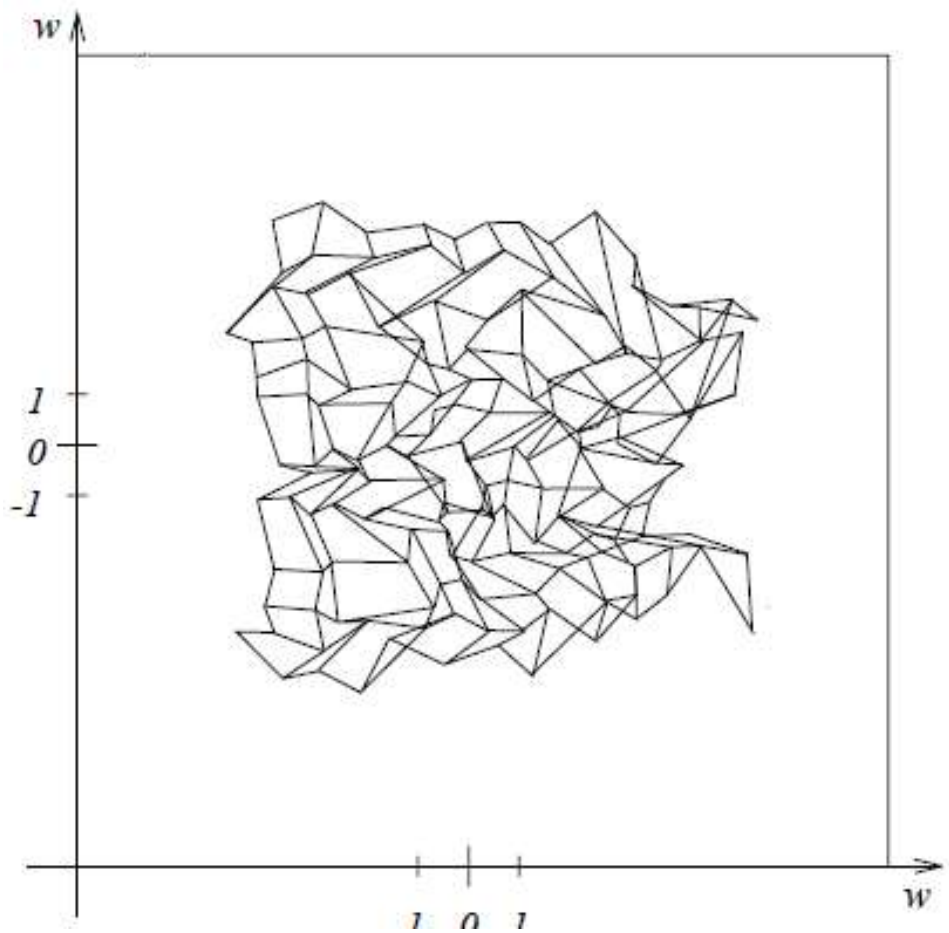

Priebeh učenia:

Kohonenova sieť – regióny pre víťazný neurón

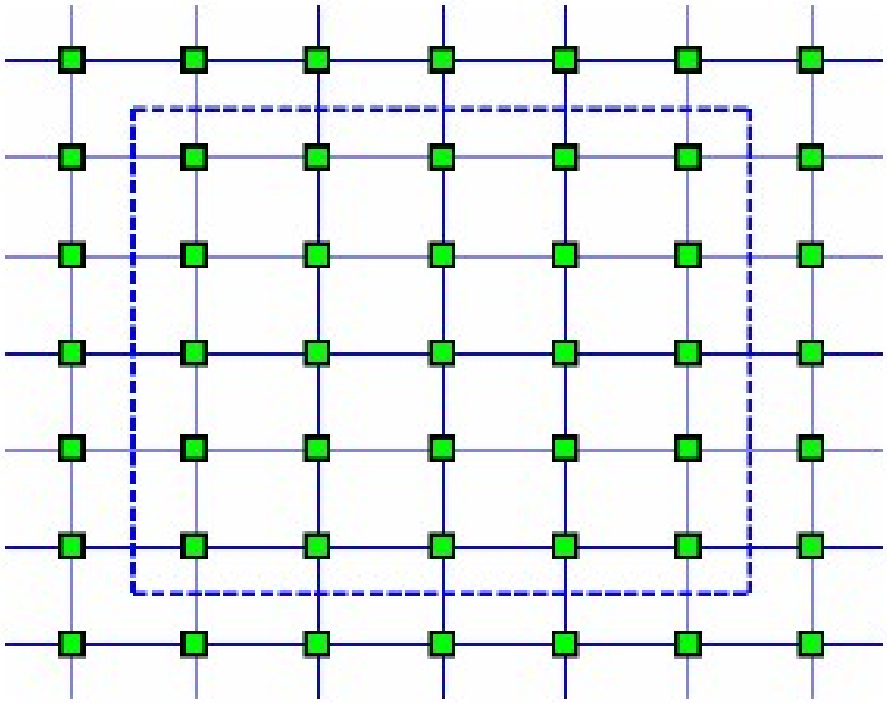

Figure 2: Square surroundings of the winning neuron, $R_c = 2$

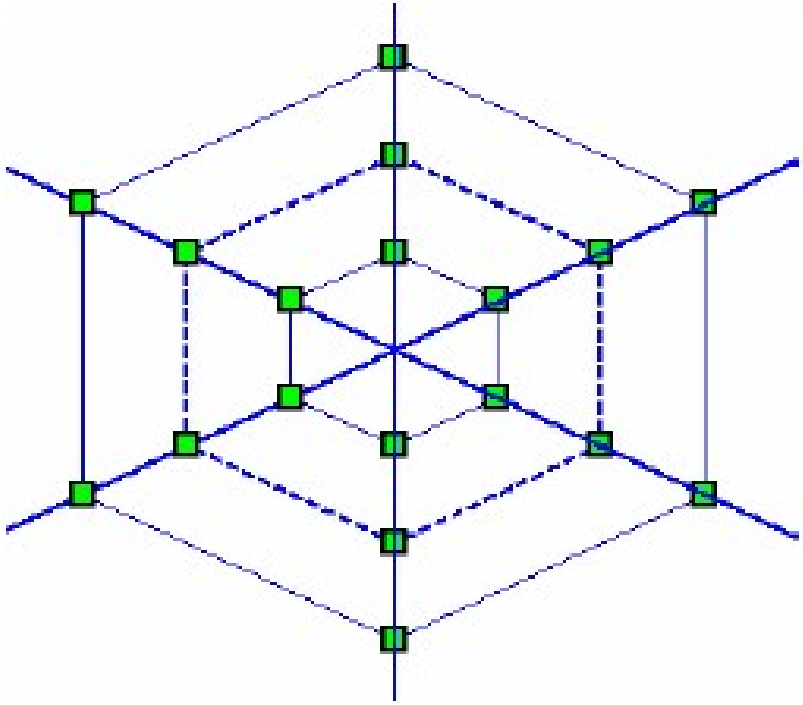

Figure 3: Hexagon surroundings of winning neuron, $R_c = 1$

Kohonenove siete

Kohonenove siete predstavujú veľmi dôležité rozšírenie konkurenčného učenia. Biologické systémy majú podobný tvar hlavne vo svojej percepčnej časti - oku. Rozšírenie konkurenčného učenia spočíva v tom, že sa pripúšťa princíp **viacerých víťazov - multiply WTA**.
Ďalej výstup z takejto NN je geometricky usporiadaný do nejakého útvaru napr. vedľa seba, kruhu, obdlžníka, a teda existuje možnosť najdenia **suseda**. Túto vrstvu nazývame **Kohonenovou vrstvou**.

Obrázok: Typická topológia Kohonenovej NN

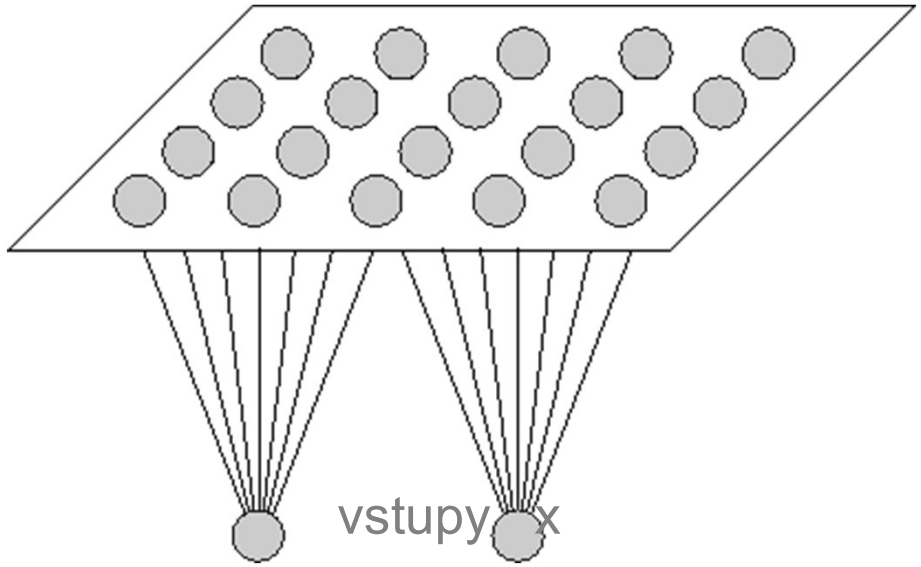

Zhlukovanie sa organizuje takým spôsobom, že susedné neuróny resp. synaptické váhy (SV), ktoré k nim smerujú, majú podobné hodnoty a tie, ktoré sú ďalej od seba, majú viac rozdielne hodnoty. Príčinou toho celého je zavedenie tzv. **susednej funkcie**. Vo väčšine prípadov ide o funkciu v tvare :

$$\lambda\left(j^*, j\right) = h(t).\exp\left(\frac{-d\left(j^*, j\right)}{r(t)}\right)$$

kde ***h*** je adaptačná výška, ***d*** je vzdialenosť medzi neurónmi v Kohonenovej vrstve a ***r*** predstavuje polomer priestorového susedstva v iterácii. Takáto funkcia môže byť vyjadrená v tvare **mexického klobúka**, ako je uvedené na obr. 5.5.

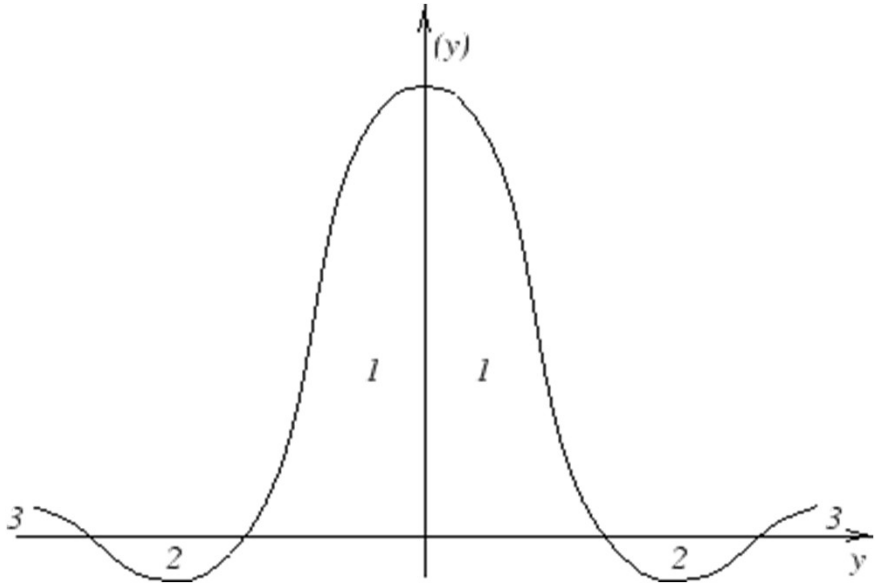

Obrázok: Možný tvar funkcie susednosti

Vzťah pre adaptáciu váh:

$$w_{ij}(t+1) = w_{ij}(t) + \eta(t).\lambda(j^*, j)\left[x_i(t) - w_{ij}(t)\right]$$

kde η je koef. učenia a λ je hodnota funkcie susednosti

Kohonenova sieť - aplikácie

- Optimalizácia polohy distribučných centier
- Zatriedenie bytov do skupín v závislosti od (lokality, počet izieb, cena, zariadenie, ...)
- Zatriedenie a vyhľadávanie dokumentov, príspevkov, inzerátov ...
- Automatická kontrola pravopisu
- Asociácie výrokov (podmienka -> akcia)
- Rozpoznanie obrazcov
- Získavanie informácií - Data mining

Príklad 1 – klasifikácia do skupín

Štruktúra Kohonenovej siete pre klasifikáciu

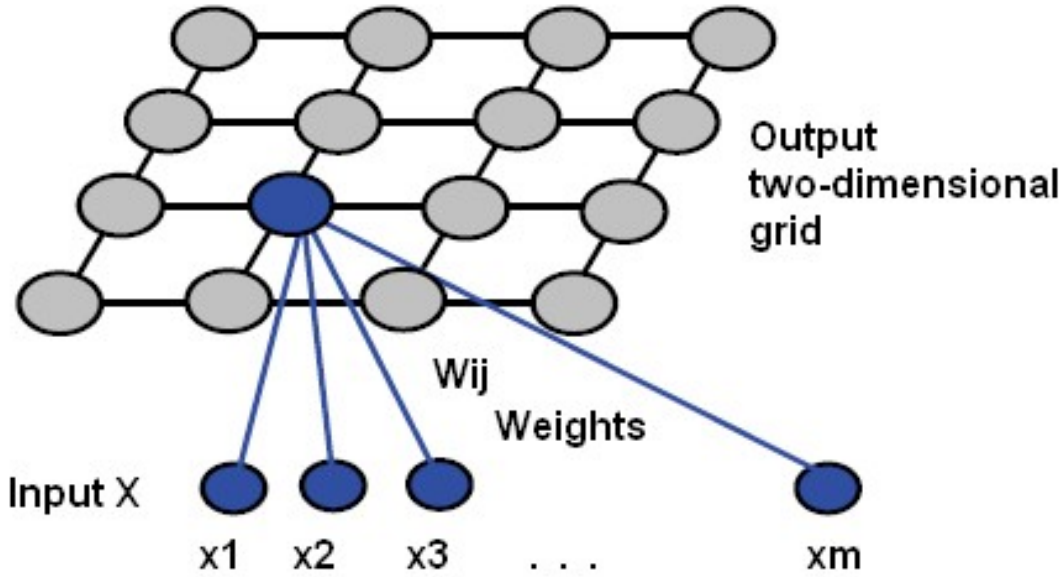

Funkcia susednosti

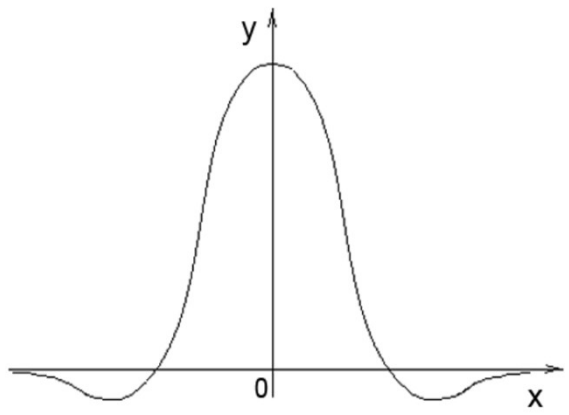

$$\lambda(j^*, j) = h(t).\exp\left(\frac{-d_E(j^*, j)}{r(t)}\right)$$

d_E – vzdialenost neurónu od víťazného v štruktúre siete

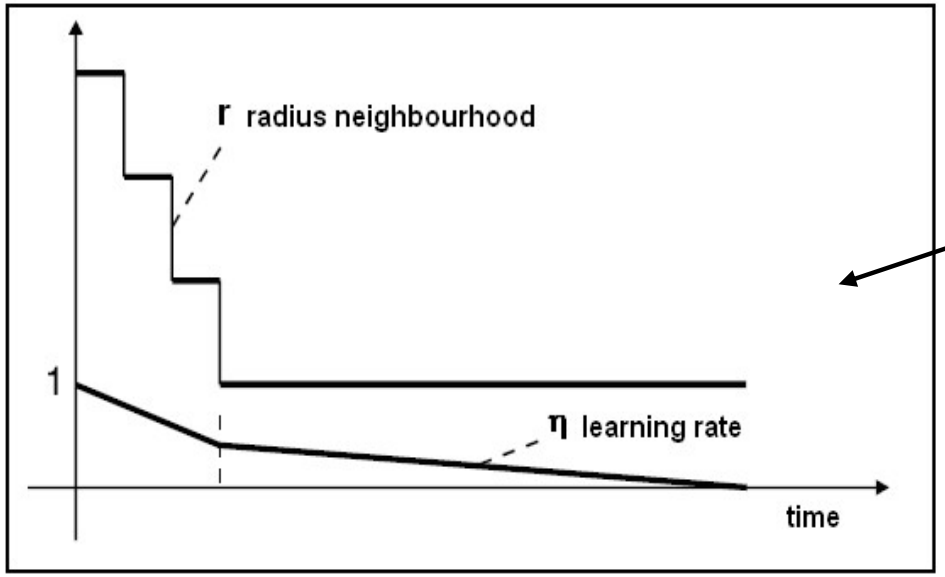

Úprava kroku učenia η a polomeru funkcie susednosti r

Adaptácia váh

$$w_{ij}(t+1) = w_{ij}(t) + \eta(t).\lambda(j^*, j)\left[x_i(t) - w_{ij}(t)\right]$$

Príklad 1 – klasifikácia do skupín

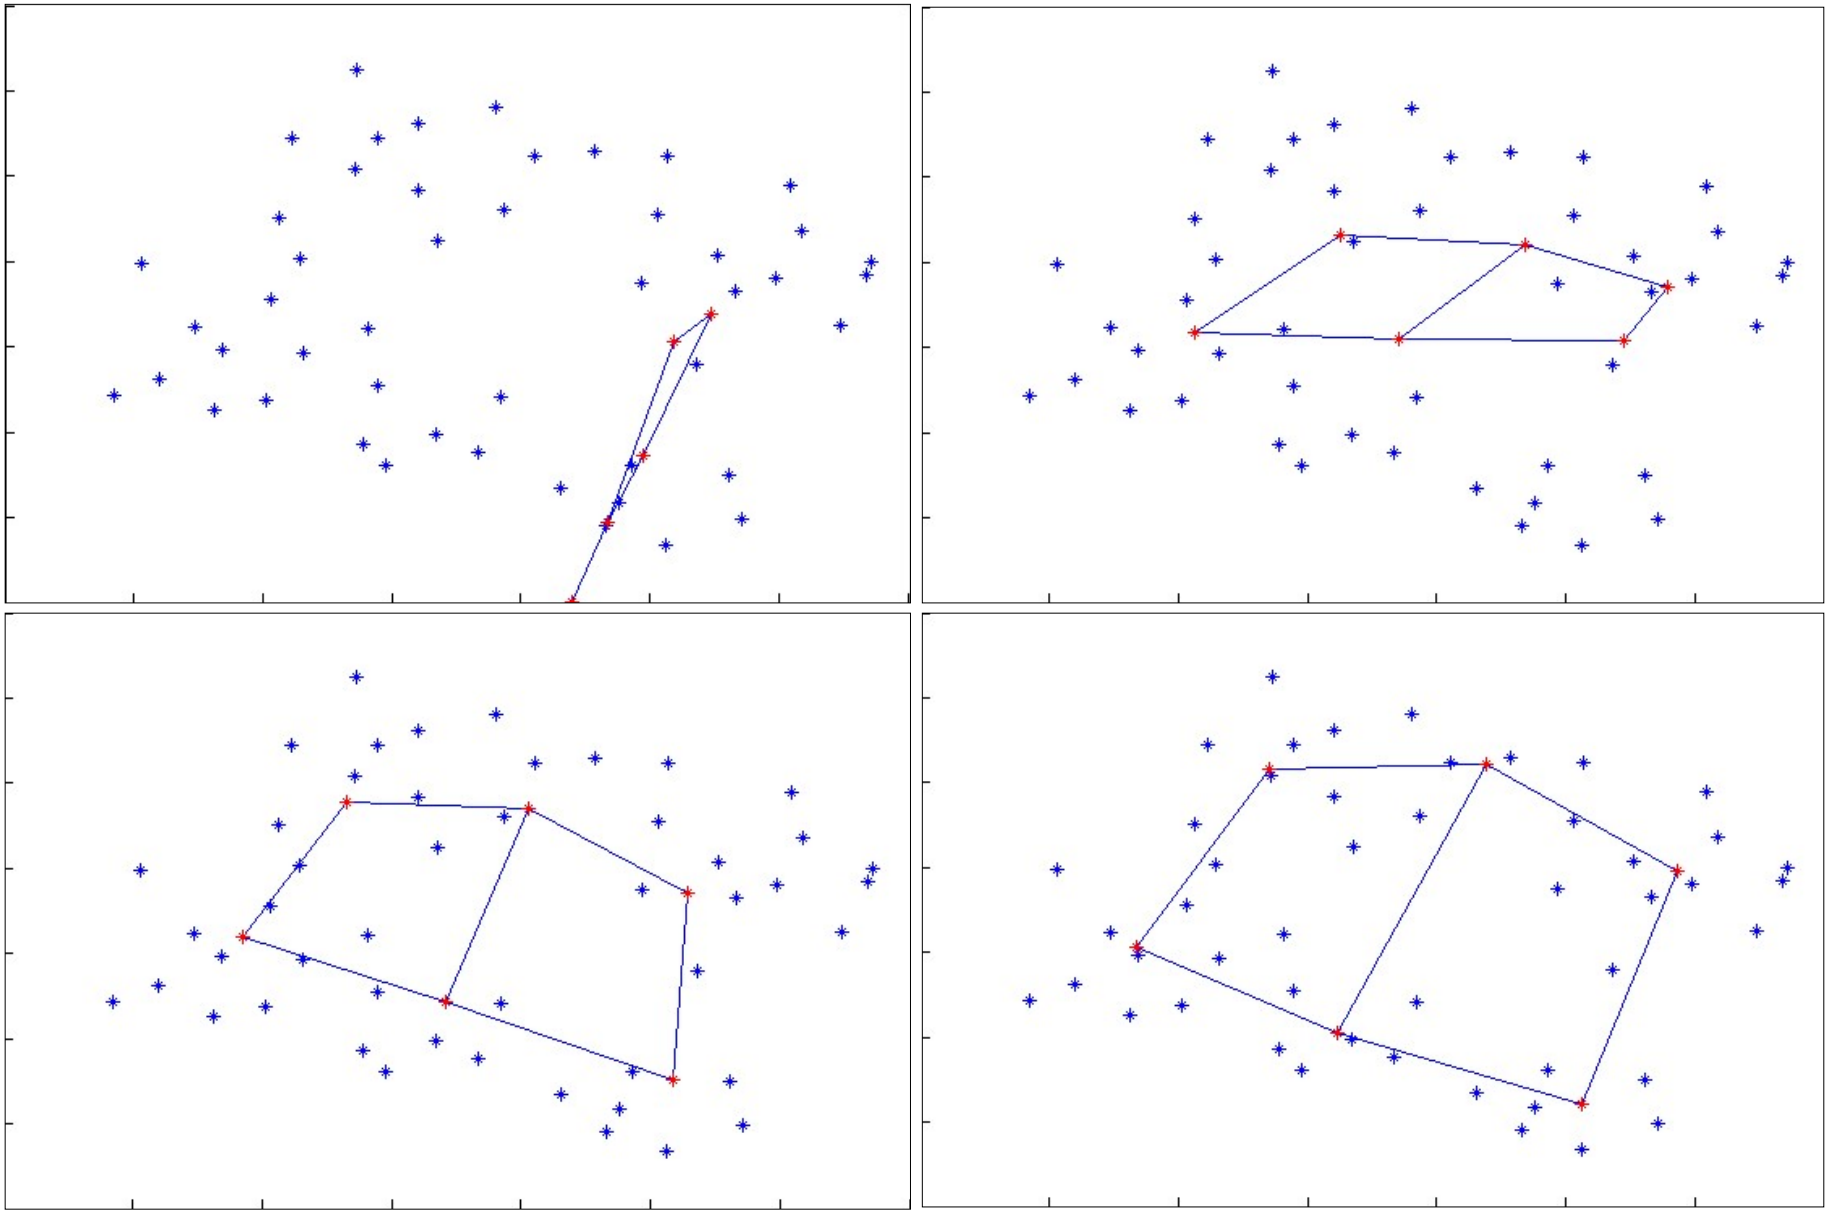

Príklad 1 – klasifikácia do skupín

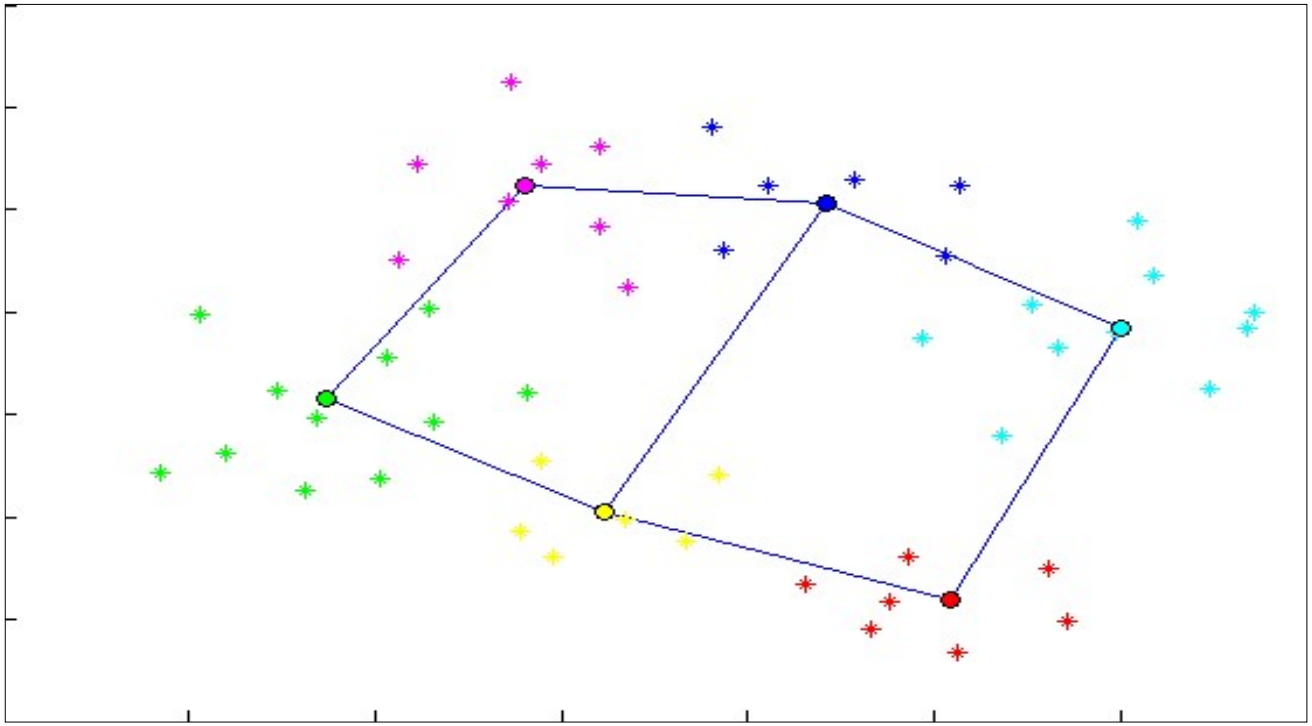

Počet cyklov (cycle)	8
Zač. krok učenia η_0	0,7
Polomer susedstva r_0	10
Výška funkcie susedstva h_0	1,2

$$\eta(t) = \exp(\eta_0 / cycle) - 1 \qquad h(t) = \exp((1 - h_0)/cycle) \qquad r(t) = r_0 . \exp(-cycle)$$

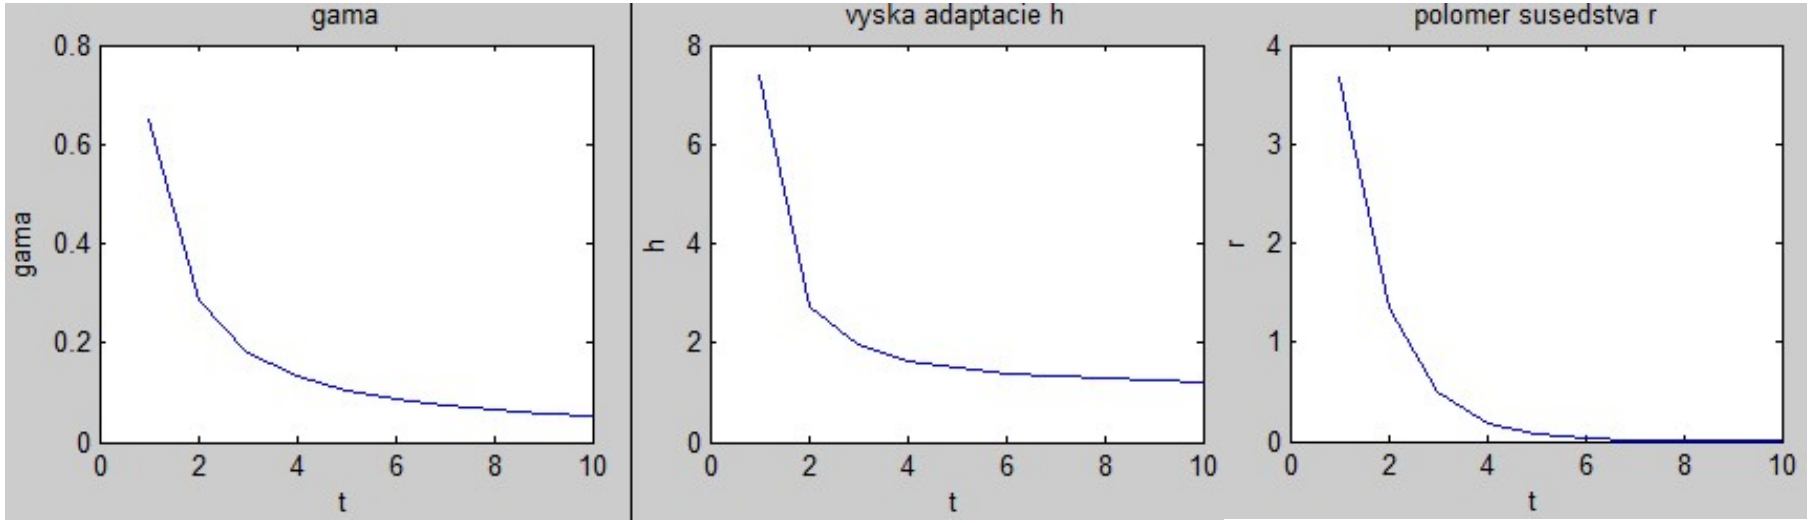

Príklad 2 – optimalizácia rozlož. distribučných centier

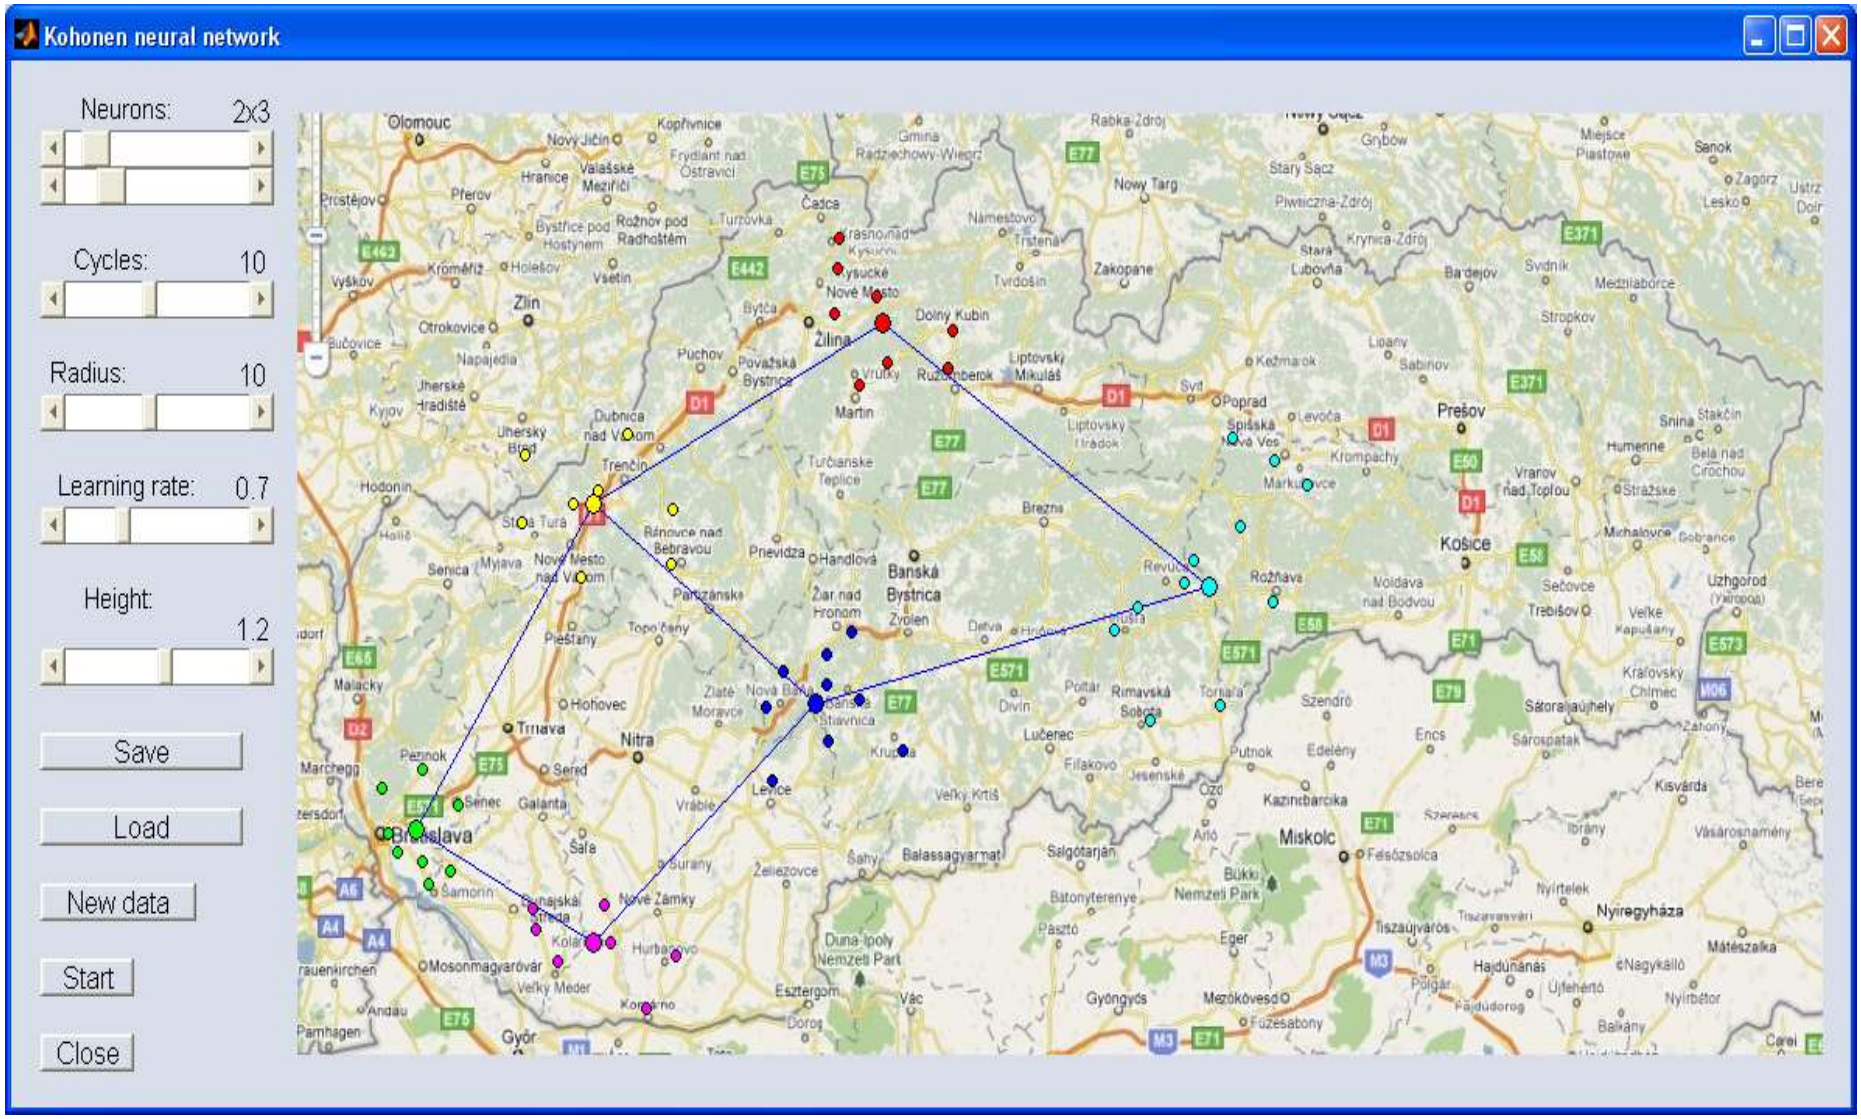

Príklad 2 – optimalizácia rozlož. distribučných centier

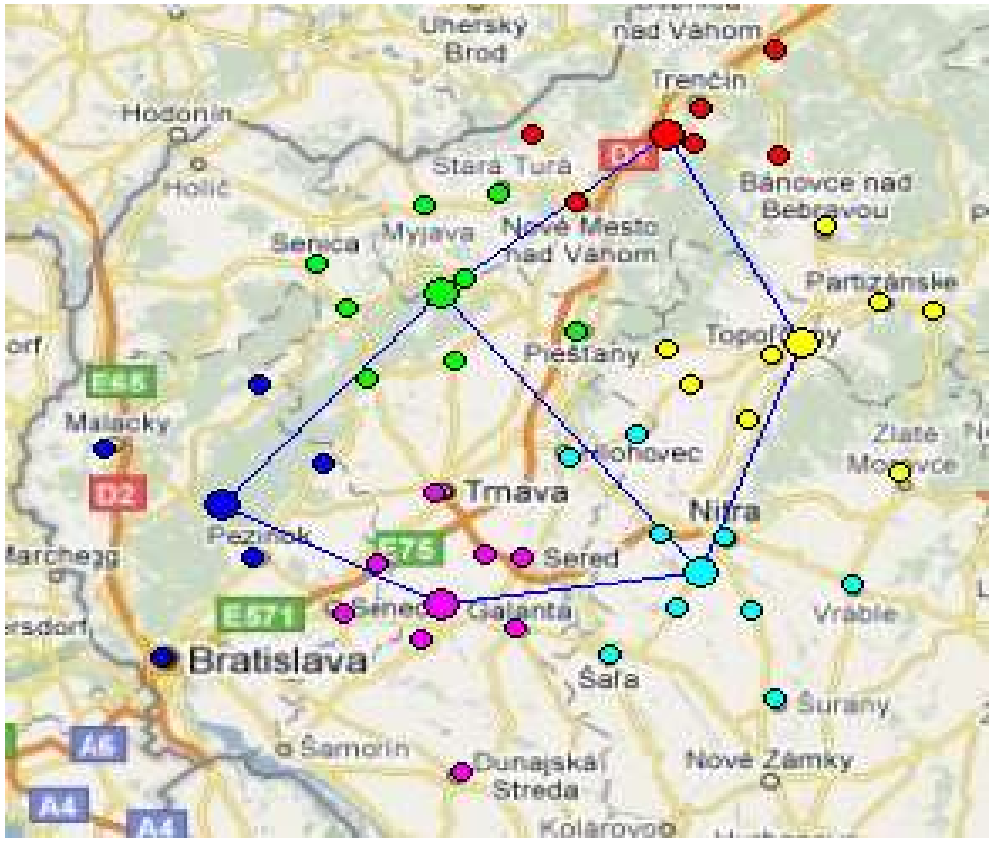

Príklad 3 – triedenie dát do skupín v databáze

No.	Name	Sex	Age	Weight	Height	....	Sport
1	Fero Mrkva	M	8	30	125	....	95
2	Anna Pekná	F	10	32	145	....	30
3	Marta Sivá	F	9	28	142	....	80
4	Peter Veľký	M	13	45	162	....	80
5	Dušan Malý	M	12	42	158	....	60
....	....	....	....	....	....	....	....
N	Pavol Ondava	M	10	38	141	....	90

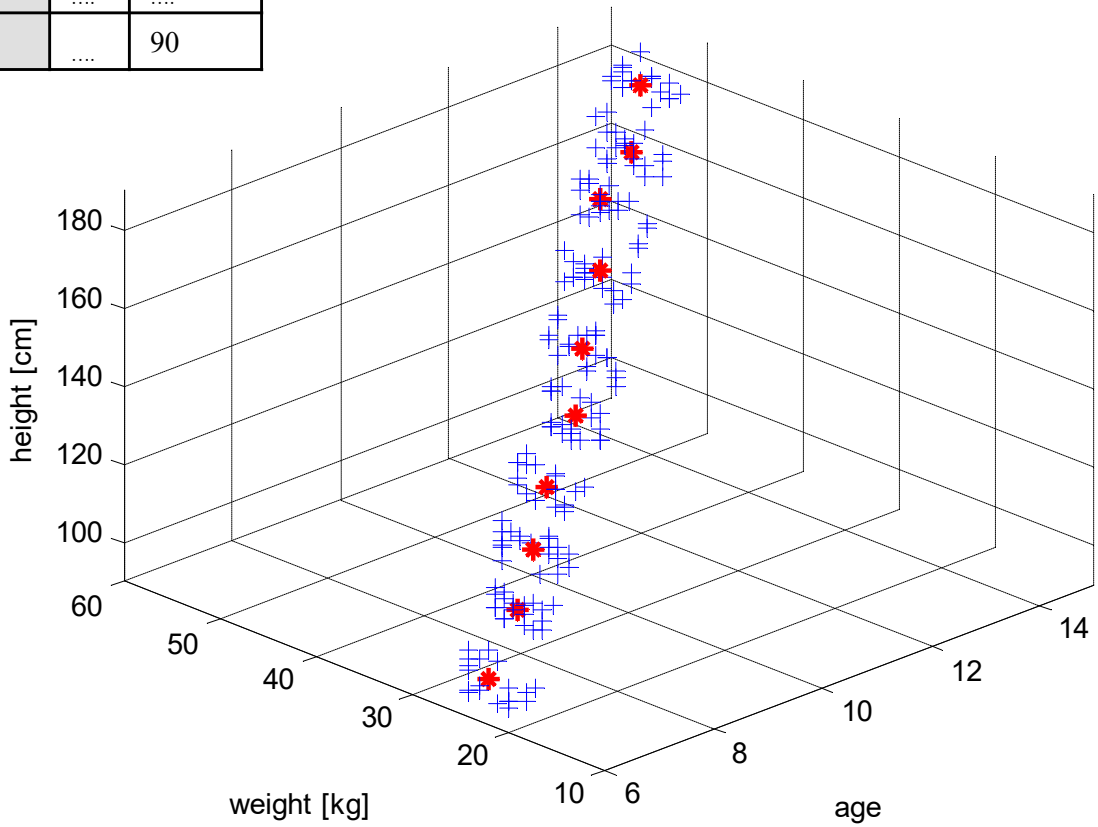

Príklad 4 – triedenie ľudí podľa záujmov

- Prvé dva atribúty človeka, s ktorými sieť pracuje, sú *vek* (0-0.6) a *pohlavie* (0-0.2).
- Vlastnosti, ktoré vyjadrujú samotnú ľudskú osobnosť, sú *ambicióznosť*, *vízia sveta*, *nálada*, *temperament*, *športový duch* (0-1) (ďalej len povahové črty)
- Hľadá aj optimálnu štruktúru (počet neurónov – skupín)

Príklad 4 – triedenie ľudí podľa záujmov

Administrátor: Miloš Lajtman

Počet skupín: 3
Kriteriálna funkcia (Jp): 20.34
Absolútna vzdialenosť (J): 15.02

Priemerný člen skupiny

Vek:
32

Pohlavie:
Muž

Skupina: 1 / **Odchýlka:**

Ambicióznosť: 26%

Vízia sveta: 29.8%

Naladenie: 35.4%

Temperament: 30.8%

Športová aktivita: 28%

Min. počet neurónov: 2

Polomer funkcie susedstva (r): 8

Percentuálna odchýlka J: 1,6

Krok/rýchlosť učenia (gama): 0,7

Váhovacia konštanta v krit. funkcii Jp (alfa): 1,5

Počet opakovaní trénovania: 3

Výška funkcie susedstva (h): 0,9

Počet cyklov učenia: 5

Uložiť | Pretrénovať

Príklad 5 – triedenie nehnutľností v databáze

- Atribúty, ktoré špecifikujú určitú nehnuteľnosť, sú nasledovné: *typ*, *cena*, *počet izieb*, *rozloha*, *vek*, *stav* a *lokalita*. (0-1).

id	foto	adresa	psc	typ	cena	izby	rozloha	vek	stav	lokalita	cluster	variation
155	f39.jpg	Laurinská 209/6, 811 01 Bratislava	811 01	0.6	78800	4	90	3	0.85	1	3	0.66
154	h38.jpg	Mierová 2160/224, 821 05 Bratislava	821 05	0.8	149200	8	173	4	0.77	0.7	5	0.42
153	f37.jpg	Tulipánová 2197/14, 841 01 Dúbravka	841 01	0	131200	4	95	2	0.18	0.6	2	0.41
152	f36.jpg	Starhradská 1710, 851 05 Petržalka	851 05	0.4	75600	4	84	25	0.57	0.4	1	0.24
151	f35.jpg	Bieloruská 5193/46, 821 06 Bratislava	821 06	0.6	100500	5	85	25	0.13	0.2	3	0.57
150	f34.jpg	Haanova 20-22, 851 04 Bratislava-Petržalka	851 04	0.2	90000	4	83	9	0.25	0.45	3	0.34
149	f33.jpg	Mokráň záhon 16434, 821 04 Bratislava	821 04	0.4	89600	4	71	2	0.08	0.65	3	0.35
148	f32.jpg	Krajná 700, 900 41 Rovinka	900 41	0	114200	2	104	50	0.7	0	1	0.77
147	f31.jpg	Beniakova 3082/30, 841 05 Karlova Ves	841 05	0.6	88300	3	70	4	0.57	0.7	3	0.32
146	h30.jpg	Čelakovského 1395/14, 811 03 Bratislava	811 03	0.8	146800	8	172	12	0.33	1	5	0.36
145	h29.jpg	Vtáčnik 11534/3, 831 01 Bratislava	831 01	0.8	123500	5	137	7	0.21	0.9	5	0.41
144	h28.jpg	Zhorinska 1406/48, 841 03 Bratislava	841 03	0.8	135600	6	174	12	0.48	0.65	5	0.25
143	f27.jpg	Podlučinského 3185/7, 821 04 Bratislava	821 04	0.2	83800	4	70	40	0.08	0.65	3	0.64

Príklad 5 – triedenie nehnutľností v databáze

Administrátor: Administrátor

Počet skupín: 5
Kriteriálna funkcia (Jp): 70.6
Absolútna vzdialenosť (J): 42.18

Min. počet neurónov
2

Polomer funkcie susedstva (r)
8

Percentuálna odchýlka J
1,3

Krok/rýchlosť učenia (gama)
0,7

Váhovacia konšt. v krit. funkcii Jp (alfa)
1,5

Počet opakovaní trénovania
3

Výška funkcie susedstva (h)
0,9

Počet cyklov učenia
5

Uložiť | Pretrénovať

Typ nehnuteľnosti:	Rodinný dom
Počet izieb:	6
Rozloha nehnuteľnosti:	126 m²
Vek nehnuteľnosti:	14.6 rokov
Stav nehnuteľnosti:	50.9%
Skupina:	4

113 973 €
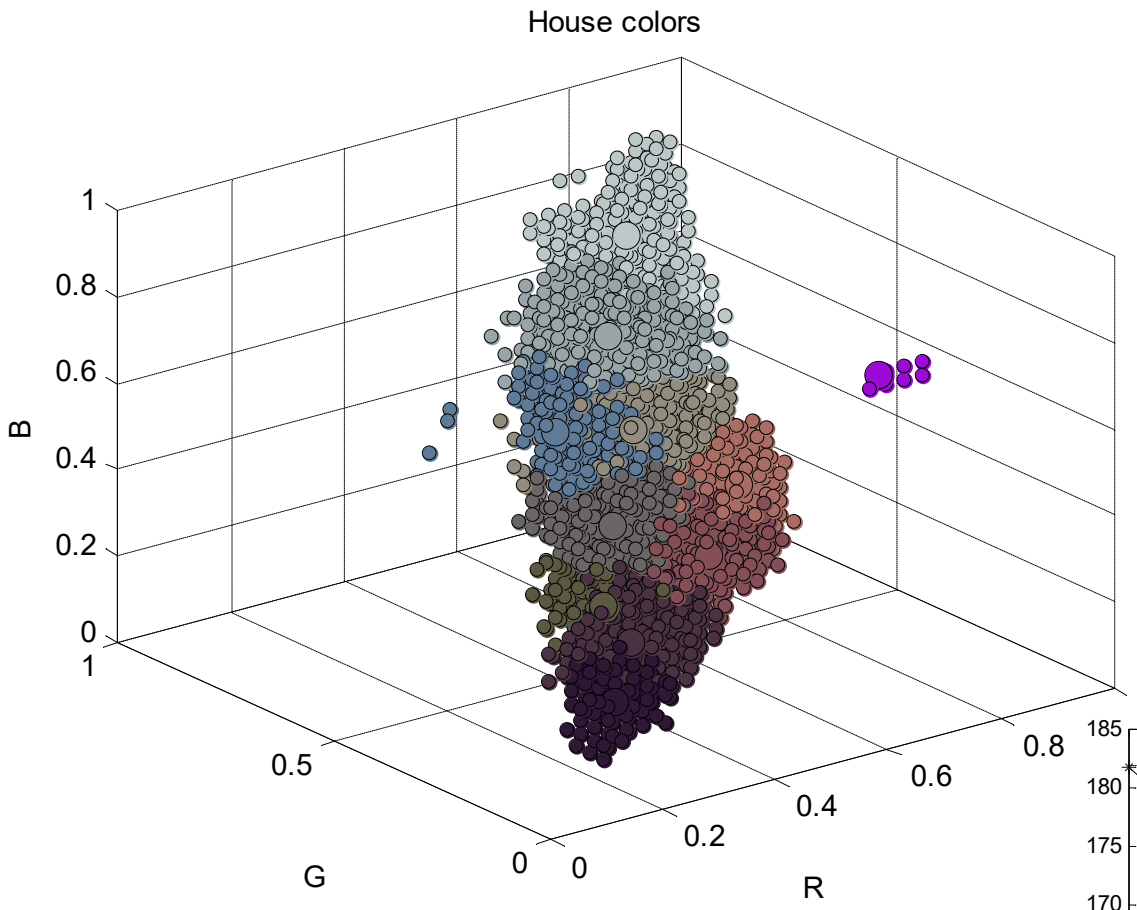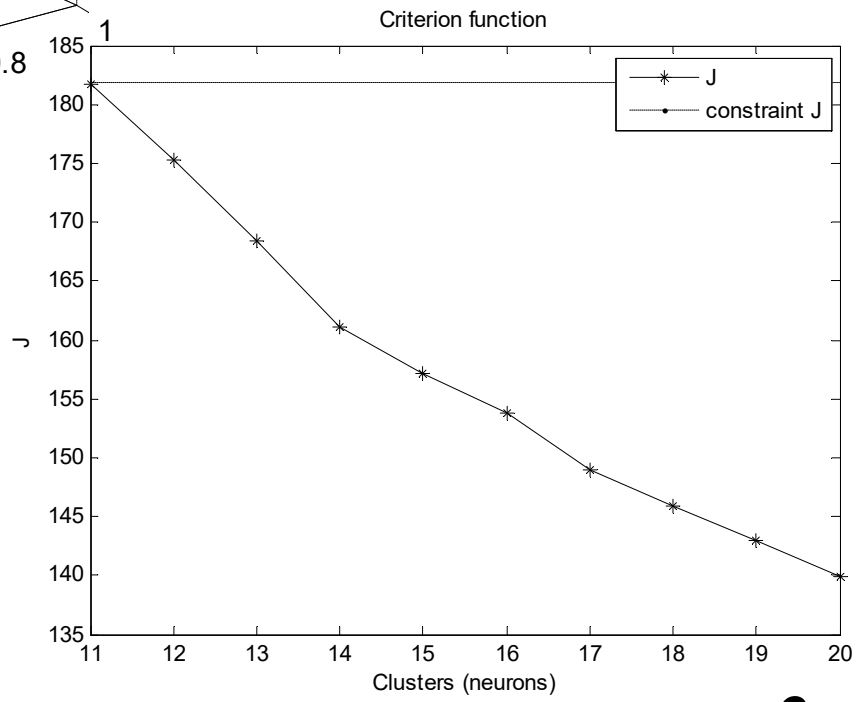
Príklad 6 – zatriedenie farieb domov do skupín